

ГЛАВА 4	Метод реализации системного оператора	FuzzyXAI
---------	--	----------

Глава 4. Практическая реализация и экспериментальная проверка структурной состоятельности объяснительно-аудиторского слоя FuzzyXAI

Системный оператор нечёткого объяснения должен быть представлен не только как математическая конструкция, но и как воспроизводимый вычислительный маршрут. Такой маршрут принимает результат модели и локальных объяснителей, сохраняет происхождение каждого утверждения, различает измеренное значение и отсутствие сведений, диагностирует нарушение обязательных связей и формирует допустимый режим применения. Поэтому предметом главы является метод вычислительной реализации FuzzyXAI и экспериментальная проверка его структурных, статистических и вычислительных свойств.

Распространённые методы локальной интерпретации решают задачу выделения признаков, областей изображения, фрагментов текста или временных интервалов, связанных с конкретным прогнозом. Такой результат не содержит автоматически полного ответа на вопросы о происхождении данных, доступности обязательных каналов, согласии нескольких источников, устойчивости объяснения и допустимости автоматического действия. Системный оператор должен включать локальную атрибуцию как свидетельство, не искажая её, и одновременно формировать проверяемую надстройку из диагностических состояний, ограничений и действий.

Экспериментальная программа главы построена вокруг заранее разделённых утверждений. Проверяются сохранение локальной верности подключённого объяснителя, локализация отсутствующих каналов происхождения, практическая полезность адаптивной политики, минимально достаточный выбор представления неопределённости, структурная и

ГЛАВА 4	Метод реализации системного оператора	FuzzyXAI
---------	--	----------

предсказательная функции критического разрыва, а также общий эффект исключения правила. Такое разделение необходимо, поскольку положительный результат для структурной функции не означает автоматически повышения точности или безопасности решения.

Доказательная база построена в два последовательно зафиксированных этапа. Первый этап охватывает четыре модальности и проверяет H1–H6 на UCI Covertypes, Fashion-MNIST, 20 Newsgroups и ElectricDevices. Второй, независимый подтверждающий контур использует Bank Marketing, Default of Credit Card Clients, Shoulder Implant X-Ray, SMS Spam Collection и UCI HAR Smartphones. Такое разделение позволяет сохранить ранние отрицательные результаты и одновременно проверить более узкие свойства H3-P1–H3-P4, H5-A, H6-A, H6-B, H7, H8 и H9 на новых данных. После автоматизированной предварительной проверки пользовательские объяснения были доработаны и представлены людям, изучающим методы объяснимого искусственного интеллекта. В качественной оценке переработанные формулировки были признаны понятными и приемлемыми; этот результат относится к читаемости представления и не заменяет количественную проверку эффективности решений.

Практическая часть дополнена описанием реальных модулей выпуска v1.3.0, типизированных структур данных, публичного интерфейса, проверяющего модуля и исполняемого сквозного примера. Эти материалы раскрывают, как формальная схема реализуется в коде и как из входного результата формируются диагностика, действие, пользовательская проекция и аудиторский пакет.

Основные результаты главы

Для быстрого ознакомления основные результаты сведены к восьми положениям. Каждое положение далее раскрывается экспериментом и связывается с доказательным источником.

ГЛАВА 4	Метод реализации системного оператора	FuzzyXAI
---------	--	----------

1. H1 и H2 подтверждают, что системный слой сохраняет исходное локальное объяснение и обнаруживает предусмотренное отсутствие обязательного канала без подстановки фиктивного значения.

2. H4 подтверждает практическую пользу иерархии представлений: средняя сложность снижена с 8 до 3,137 при сохранении зарегистрированного риска и действия полного представления.

3. H5-S и H5-A подтверждают структурную диагностику и сертификацию маршрута только для зарегистрированных классов нарушений.

4. H7-A подтверждает точное сохранение 17 404 канонических объяснительных артефактов. Количественная гипотеза H7-B об улучшении сокращённой проекции не подтверждена.

5. H3, H5-P и H6-general не подтверждены: системный оператор не является универсально лучшей политикой, критический разрыв не предсказывает ошибку, а удаление правила не имеет общего направленного эффекта.

6. H6-A подтверждена лишь в синтетической области обнаружимости; H6-B на реальных правилах имеет описательный статус.

7. H8 и H9 являются ограниченными техническими измерениями: компонентная сетка влияет на состав причин, а масштабирование до 5 млн записей относится только к кэшированному операторному слою.

8. Практический вклад состоит в воспроизводимом аудите происхождения, сохранении свидетельств, локализации структурных нарушений и управлении формой представления. Реализация включает публичный API, адаптеры модальностей, типизированный OperatorRoute, проверяемый ProofTrace и экспорт JSON/CSV/PNG/HTML. Пользовательская понятность и предметная эффективность требуют отдельного количественного исследования.

ГЛАВА 4	Метод реализации системного оператора	FuzzyXAI
---------	--	----------

Основные термины

Термин	Принятое значение
Вычислительное свидетельство	Измеренный факт с указанием значения, источника, версии компонента и допустимой области интерпретации.
Утверждение (утверждение)	Фраза объяснения, связанная хотя бы с одним вычислительным свидетельством.
Происхождение (provenance)	Проверяемая цепочка от исходных данных и компонента до утверждения, диагностики и действия.
Источник	Конкретный вычислительный компонент, модель, набор данных или объяснитель.
Канал	Тип доступных сведений: прогноз, атрибуция, правило, история обучения, устойчивость или иная группа свидетельств.
Критический разрыв	Отсутствие допустимого маршрута от обязательных свидетельств к автоматическому действию.
Канонический артефакт	Неизменяемая исходная форма объяснения, сохраняющая значения, параметры, идентификаторы и контрольную сумму.
Пользовательская проекция	Сокращённое представление канонического объекта для выбранной аудитории без изменения исходного артефакта.
ООФ-выборка	Объекты с признаками и прогнозами, полученными вне обучающего поднабора соответствующего разбиения.
Контрольная выборка	Изолированная совокупность, не используемая при настройке моделей, политик и порогов.

Далее термины используются в приведённых значениях. Английские эквиваленты сохраняются только при первом упоминании, в названиях методов, интерфейсов и машинных артефактов.

4.1 Постановка задачи вычислительной реализации и проверяемые утверждения

Пусть M обозначает обученную модель, x — исследуемый объект, P — план построения объяснения, а Ω — набор ограничений вычислительного и предметного контекста. Вычислительная реализация должна преобразовывать эти входы в объяснительный объект E , диагностическое состояние D , действие χ и доказательный след τ . В отличие от функции локальной атрибуции, оператор формирует не только ранжирование причин, но и проверяемую структуру перехода от свидетельств к действию.

Вычислительным свидетельством считается измеренный факт, для которого указаны значение, источник, версия вычислительного компонента и

ГЛАВА 4	Метод реализации системного оператора	FuzzyXAI
---------	--	----------

допустимая область интерпретации. Свидетельством может быть вероятность класса, локальная атрибуция, правило, мера сдвига, оценка устойчивости, информация о версии модели или факт отсутствия обязательного канала. Утверждение объяснения допускается к отображению только при наличии связи хотя бы с одним свидетельством и при отсутствии запрещающего диагностического состояния.

$$\mathcal{O} : (M, x, \Pi, \Omega) \mapsto (E, D, \chi, \tau) \quad (4.1)$$

Объяснительный объект представлен как типизированная структура, объединяющая множество свидетельств V , множество пользовательских утверждений C , отношения происхождения R , профиль неопределённости U и политику представления P . Такое представление позволяет отделить измеренный факт от его словесной интерпретации и явно указать, какая часть объяснения недоступна.

$$E = \langle V, C, R, U, P \rangle \quad (4.2)$$

Диагностическое состояние содержит признаки неполноты, конфликта, нестабильности, сдвига и превышения допустимой потери при редукции. Действие выбирается не по одной величине уверенности, а по совокупности доступных свидетельств и ограничений. При отсутствии обязательного канала оператор обязан вернуть диагностическое состояние; числовая подстановка по умолчанию запрещена.

$$D = (d_miss, d_conf, d_stab, d_shift, d_red) \quad (4.3)$$

$$\chi(E, D) = \arg \min_a R(a \mid E, D), a \in \{\text{принять, проверить, заблокировать}\} \quad (4.4)$$

Экспериментальная проверка организована как проверка отдельных гипотез. H1 относится к сохранению исходной локальной верности. H2 проверяет обнаружение удалённых каналов происхождения. H3 проверяет превосходство адаптивной политики над сильной простой политикой. H4 относится к снижению сложности представления при сохранении риска. H5

ГЛАВА 4	Метод реализации системного оператора	FuzzyXAI
---------	--	----------

разделена на структурную и предсказательную части. H6 проверяет общий специфический эффект исключения правила относительно сопоставимого случайного удаления.

Обозначение	Проверяемое свойство	Критерий интерпретации
H1	Сохранение верности исходного объяснителя	Неухудшение в пределах $\varepsilon = 0,02$ при одинаковом объекте и бюджете
H2	Локализация отсутствующего канала	F1 обнаружения и отсутствие ложной сертификации
H3	Практическая польза адаптивной политики	Меньший риск при сопоставимом покрытии либо меньшая стоимость при не худшем риске
H4	Минимально достаточное представление	Риск не выше постоянного выбора FML + ε при меньшей сложности
H5-S	Структурный критический разрыв	Обнаружение и локализация нарушенного маршрута
H5-P	Предсказательная функция разрыва	Положительный прирост AUPRC относительно модели без признака
H6	Специфический эффект абляции правила	Эффект правила-кандидата выше эффекта сопоставимых контрольных правил на независимых наборах

Таблица 4.1 — Проверяемые свойства вычислительного контура

Предварительная фиксация критериев необходима для исключения ретроспективного изменения цели эксперимента. Если утверждение не подтверждается, оно не заменяется более удобным постфактум-выводом. В этом случае область применения метода сужается, а неподтверждённое свойство исключается из перечня научных результатов.

4.2 Архитектура доказательного вычислительного контура

Вычислительный маршрут начинается с приведения разнородных выходов модели и объяснителей к нормальной форме свидетельства. Для каждого элемента фиксируются тип, значение, единица интерпретации, идентификатор источника, версия модели, объект и время получения. Нормализация обеспечивает совместную обработку коэффициентов линейной модели, правил дерева, локальных атрибуций, областей изображения, токенов и временных окон.

Рисунок 4.1 — Архитектура доказательного вычислительного контура

ГЛАВА 4	Метод реализации системного оператора	FuzzyXAI
---------	--	----------

Нормализованные свидетельства образуют доказательный граф. Его узлы соответствуют исходным данным, вычислительным компонентам, свидетельствам, утверждениям, диагностическим состояниям и действиям. Рёбра задают отношения происхождения, агрегации, редукции и запрета. Граф используется не как визуальная метафора, а как исполнимая структура: проверочный модуль может восстановить путь от пользовательской фразы до исходного вычислительного артефакта.

После построения графа формируется профиль неопределённости. Он включает калибровочную неопределённость прогноза, расхождение моделей и объяснителей, нестабильность причин, неполноту происхождения и сдвиг данных. По профилю выбирается минимально достаточная форма представления из классов F0, Fint, NAS и FML. Сложная форма не должна применяться автоматически, если более простая форма сохраняет необходимое покрытие.

$$F^*(u) = \arg \min_F C(F), \text{ при } \text{Cover}(F,u)=1 \text{ и } \Delta(F,u) \leq \delta \quad (4.5)$$

Диагностический модуль реализует принцип запрета автоматического завершения при неполноте. Если обязательный канал отсутствует, версия компонента несовместима или редукция превышает допустимую потерю, маршрут не завершается автоматическим действием. В систему не вводится фиктивное нулевое значение, поскольку ноль является измеренным значением, а отсутствие свидетельства — отдельным логическим состоянием.

Последним этапом является редукция объяснения под адресата. Предметному пользователю выводятся решение, основные наблюдаемые причины, ограничения и действие. Техническому специалисту дополнительно доступны согласие источников, устойчивость и сведения о версиях. Аудитор получает полный граф происхождения. Все уровни

ГЛАВА 4	Метод реализации системного оператора	FuzzyXAI
---------	--	----------

представления строятся из одного объекта E, поэтому сокращение не создаёт нового независимого объяснения.

Компонент	Вход	Результат	Проверяемый инвариант
Нормализация	Выход модели или объяснителя	Типизированное свидетельство	Сохранение значения и источника
Доказательный граф	Свидетельства и зависимости	Связный маршрут происхождения	Каждое отображаемое утверждение связано со свидетельством
Выбор представления	Профиль неопределённости	F0, Fint, NAS или FML	Минимальная сложность при достаточном покрытии
Диагностика	Граф и ограничения	Состояния неполноты, конфликта, сдвига	Отсутствие не заменяется числом
Политика действия	E, D и функция риска	принять, проверить или заблокировать	Действие воспроизводимо из зафиксированных параметров
Редукция	Полный объект E и профиль адресата	Пользовательская карточка	Происхождение ключевых утверждений сохраняется

Таблица 4.2 — Основные компоненты вычислительного маршрута

Программная реализация включает проверочные контракты, которые запрещают использование тестовой выборки при калибровке, фиксируют версии зависимостей, сохраняют идентификаторы объектов и формируют контрольные суммы артефактов. Таким образом, вычислительная архитектура одновременно реализует оператор и создаёт условия для его независимого повторения.

4.2.1 Программные компоненты и соответствие формальной модели

Практическая реализация разделена на адаптеры, нормализацию, построение маршрута, выбор представления, диагностику, действие, проверку доказательного следа и экспорт. Благодаря этому модель и локальный объяснитель могут заменяться без изменения последующих контрактов. В таблице 4.2а приведено соответствие функций реальным модулям выпуска v1.3.0.

Функция	Реальный модуль	Вход	Выход	Контролируемый отказ
Приём внешнего результата	fuzzyxai/adapters/ base.py; tabular_classification. py	payload модели и объяснителя	AdaptedInput	отсутствующее поле или неверный диапазон

ГЛАВА 4		Метод реализации системного оператора	FuzzyXAI	
Функция	Реальный модуль	Вход	Выход	Контролируемый отказ
Нормальная форма	fuzzyxai/core/ types.py; core/explanation.py	AdaptedInput	ExplainableObject	неполный канал фиксируется явно
Построение маршрута	fuzzyxai/core/ route.py; external_tabular_route .py	объяснительный объект и план	OperatorRoute	несовместимый сценарий или версия
Выбор представления	fuzzyxai/risk/ representation_selecti on.py; hierarchy/*	профиль неопределённости	F0/Fint/NAS/FML	недокрытие или чрезмерная редукция
Диагностика и действие	fuzzyxai/operators/ diagnostics.py; operators/actions.py	γ , Δ , ρ и контракт маршрута	diagnostic_id и action_id	структурное нарушение локализуется
Доказательный след	fuzzyxai/proof/ trace.py; proof/verifier.py	OperatorRoute	ProofTrace и VerificationResult	несогласованность значений, действия или диагностики
Экспорт	fuzzyxai/runtime.py; visualization/traceabili ty.py	проверенный маршрут	JSON, CSV, PNG, HTML	пакет не создаётся при некорректном входе

Таблица 4.3 — Соответствие практических функций программным модулям

4.2.2 Исполняемые структуры данных

Внутренний обмен основан на типизированных структурах из fuzzyxai/core/types.py. Адаптер формирует AdaptedInput, вычислительная часть создаёт OperatorRoute, а проверяемый пакет представлен ProofTrace. Эти структуры разделяют входные значения, вычисленные результаты, диагностику, действие и версию источника.

Структура	Ключевые поля	Назначение
AdaptedInput	scenario_id, values, source, value_sources, metadata	Нормализованный вход после проверки адаптером
OperatorNode	node_id, input_values, output_values, formula_text, thresholds, status, next_node_ids	Восстанавливаемый шаг вычислительного маршрута
OperatorRoute	nodes, edges, computed_result, diagnostics, final_action, source_commit	Полный маршрут от входа до действия
ProofTrace	route, computed_result, diagnostics, final_action, verifier_status	Снимок маршрута для независимой проверки
VerificationResult	valid, errors	Результат проверки согласованности пакета

Таблица 4.4 — Основные исполняемые структуры FuzzyXAI

ГЛАВА 4	Метод реализации системного оператора	FuzzyXAI
---------	--	----------

Минимальный вход внешней табличной модели содержит прогноз, вероятностную оценку, значения признаков, локальные важности и показатели качества. Реальный публичный пример имеет следующий вид.

Листинг 4.1 — Сокращённый payload внешней табличной модели

```
payload = { "scenario_id": "external_wine_classification", "source_type":
"tabular", "model_name": "ExternalDemoModel", "dataset_name":
"manual_payload", "predicted_class": 1, "class_probability": 0.68,
"feature_values": {"x1": 0.4, "x2": 0.7, "x3": 0.2}, "feature_importance": {"x1":
0.31, "x2": 0.18, "x3": 0.12}, "quality_metrics": {"missing_rate": 0.05,
"feature_range_violation": 0.0} }
```

4.2.3 Сквозной практический запуск

Сквозной пример выполнен через публичный класс FuzzyXAI и адаптер tabular_classification. Он не является новым статистическим экспериментом и демонстрирует уже реализованный маршрут. Проверка payload предшествует формированию девяти узлов: входного артефакта, объяснительного объекта, представления, согласования, редукции, риска, диагностики, действия и доказательного следа.

Рисунок 4.2 — Сквозной маршрут внешнего табличного примера

Этап	Расчёт или результат	Интерпретация
Внешняя модель	$p = 0,68$; missing rate = 0,05	Модель уверена не полностью, вход не содержит критического дефекта
Согласование	$\gamma = \max(0,32; 0,05; 0; 0) = 0,32$	Ограничение связано преимущественно с неопределённостью модели
Редукция	$\Sigma \text{top-k} = 0,61$; $\Delta = 1 - 0,61 = 0,39$	В сокращённый набор не вошло 39 % атрибутивной массы
Риск	$\rho = \max(0,32; 0,39; 0,05; 0) = 0,39$	Доминирующим компонентом является потеря редукции
Диагностика	D_external_tabular_uncertainty	Зафиксировано ограничение доверия, а не ошибка прогноза
Действие	lower_confidence	Результат не блокируется, но не принимается с полным доверием
Проверка	9 из 9 проверок согласованности пройдены	Формулы, значения, диагностика и действие совпадают в route и proof trace

ГЛАВА 4	Метод реализации системного оператора	FuzzyXAI
---------	--	----------

Таблица 4.5 — Значения сквозного практического запуска

Экспорт пакета создаёт route.json, operator_trace.json, operator_table.csv, proof_trace.json, verifier_report.json, dashboard_data.json, PNG- и HTML-представления. Эти файлы формируются методом export_package и не требуют ручного переноса итоговых значений в интерфейс.

4.2.4 Примеры адаптации четырёх модальностей

Практические адаптеры преобразуют разнородные входы в один тип объяснительного объекта. Приведённые примеры являются существующими фикстурами реализации и не используются как дополнительные статистические эксперименты.

Модальность	Существующий пример	Нормализованный результат	Практическое ограничение
Табличные данные	Контролируемый объект № 85: модельный балл 0,806; вклады 0,546, 0,180 и 0,080	Утверждения C-001–C-016, история обучения и действие defer_to_human	Демонстрация трассировки, а не производственный кейс
Изображение	Исследовательское изображение: категория B; пересечение областей 89 %, техническое сходство 82 %	Сохраняются поддерживающий пример и контрпримеры	Категория не трактуется как диагноз; предметный словарь не задан
Текст	Фикстура «Acute sepsis but stable now», ICD A41.9, p = 0,70	conflict = true; uncertainty = 0,456	Маркеры высокого и низкого риска повышают неопределённость
Временной сигнал	Контрольный ЭКГ-сценарий: качество 0,58; шум 0,34; два пропуска	Интервальное представление и действие defer_to_human	Оценивается качество сигнала, медицинская диагностика не выполняется

Таблица 4.6 — Практические примеры адаптации разных модальностей

4.2.5 Практическое поведение при нарушении контракта

Агрегированная F1 не показывает, что именно происходит при нарушении. Валидатор возвращает тип события, источник, критичность и рекомендуемое действие. В таблице 4.2д приведены четыре зарегистрированных сценария Н5-А.

Сценарий	Нарушенный контракт	Диагностический результат	Допустимое поведение
Несовпадение версии модели	Объяснение относится к иной версии модели, чем прогноз	Локализуется несовместимая пара model/explainer	Автоматическое применение приостанавливается до

ГЛАВА 4	Метод реализации системного оператора	FuzzyXAI
---------	--	----------

Сценарий	Нарушенный контракт	Диагностический результат	Допустимое поведение
Отсутствующее происхождение	Обязательный канал не имеет source/trace	Отсутствие фиксируется отдельно от нулевого значения	согласования версий Запросить источник либо перевести маршрут в проверку
Несовместимая предобработка	Схема признаков или преобразование не совпадает с manifest	Указывается переход preprocessing → model	Не объединять атрибуции до восстановления одинаковой схемы
Повреждённая контрольная сумма	Канонический артефакт не совпадает с SHA256	Пакет признаётся несогласованным	Не использовать проекцию; восстановить исходный артефакт

Таблица 4.7 — Практические сценарии диагностического отказа

```
{ "diagnostic_id": "D_external_tabular_uncertainty", "diagnostic_type":
"external_tabular_uncertainty", "source": "external_tabular_adapter", "criticality":
"medium", "message_ru": "ограниченная уверенность внешней табличной
модели", "recommended_action": "lower_confidence" }
```

Листинг 4.2 — Реальный формат диагностического сообщения

4.2.6 Подключение новой модели и эксплуатационный запуск

Для подключения внешней модели разработчик выбирает существующий адаптер либо регистрирует новый класс, реализующий проверку входа и преобразование payload в AdaptedInput. Последующие этапы маршрута при этом не изменяются.

Листинг 4.3 — Публичный сценарий запуска FuzzyXAI

```
from fuzzyxai import FuzzyXAI, ExplainPlan from fuzzyxai.adapters import
get_adapter    fxai = FuzzyXAI(plan=ExplainPlan.default()) adapter =
get_adapter("tabular_classification") route = fxai.run_payload(payload, adapter)
verification = fxai.verify(route) paths = fxai.export_package(route, "out")
print(route.computed_result) print(verification.valid) print(paths["proof_trace"])
```

Последовательность интеграции включает регистрацию схемы входа, описание обязательных полей, проверку диапазонов, преобразование в AdaptedInput, запуск маршрута, проверку ProofTrace и экспорт пакета. Для одиночного запроса используется run_payload; пакетный режим выполняет

ГЛАВА 4	Метод реализации системного оператора	FuzzyXAI
---------	--	----------

тот же контракт для набора объектов; кэшированный режим H9 применяется после получения прогнозов и исходных объяснений.

Листинг 4.4 — Команды установки и воспроизведения

```
pip install -e framework/fuzzyxai PYTHONPATH=framework/fuzzyxai
python scripts/check_fuzzyxai_cli.py docker build -f Dockerfile.q1-final -t
fuzzyxai-q1-final . docker run --rm fuzzyxai-q1-final make reproduce-q1-final
```

4.2.7 Состав полного времени и практический результат

Полный эксплуатационный конвейер включает четыре различающихся по природе компонента времени:

$$T_{total} = T_{model} + T_{explainer} + T_{FuzzyXAI} + T_{serialization} \quad (4.5a)$$

Компонент	Что включает	Статус измерения в главе
T_model	Получение прогноза внешней модели	Зависит от модели; не является предметом H9
T_explainer	SHAP, LIME, Grad-CAM или иной локальный метод	Не измерялось в эксперименте на 5 млн объектов
T_FuzzyXAI	Нормализация, выбор представления, риск, диагностика и действие	Измерено в H9 для кэшированного операторного слоя
T_serialization	Формирование JSON/CSV/PNG/HTML и запись пакета	Измеряется отдельно в runtime-экспорте, но не входит в H9

Таблица 4.8 — Компоненты времени полного эксплуатационного конвейера

Практическим результатом реализации является исполняемый контракт для разнородных объяснений. Он обеспечивает единый формат входа, сохранение канонического артефакта, локализацию нарушения, воспроизводимое действие, пользовательскую проекцию и аудиторский пакет. Эти функции проверяются независимо от того, дала ли политика действия статистическое преимущество над пороговой базовой схемой.

4.3 Методика экспериментальной проверки

Итоговая экспериментальная программа использует четыре реальные многоклассовые задачи. Такой выбор устраняет зависимость выводов от одного малого табличного набора и проверяет переносимость нормальной

ГЛАВА 4	Метод реализации системного оператора	FuzzyXAI
---------	--	----------

формы свидетельств между принципиально различными представлениями входных данных. Для каждого контура сформирован фиксированный список объектов, на которых сравниваются объяснители и системная оболочка.

Рисунок 4.3 — Организация многомодальной экспериментальной проверки

Таблица 4.9 — Реальные контуры экспериментальной проверки

Тип данных

Набор данных

Классов

Объектов

Объектов для оценки объяснений

Табличные

UCI Coverture

7

581 012

1 000

Изображения

Fashion-MNIST

10

70 000

500

Текст

20 Newsgroups

20

18 846

500

Врем. ряды

ГЛАВА 4	Метод реализации системного оператора	FuzzyXAI
---------	--	----------

Electric- Devices

7

16 637

500

Таблица 4.10 — Карта всех экспериментальных контуров главы

Контур

Объём

Основная величина

Фактический результат

Статус

H1: сохранение локального объяснения

6 000 пар

Разность локальной верности

0,000; 95%-й ДИ [0,000; 0,000]

Подтверждено

H2: неполнота происхождения

2 000 удалений

F1 и ложная сертификация

F1 = 1,000; ложная сертификация = 0

Подтверждено

H3: политика действия

2 500 объектов

Риск и автоматическое покрытие

Адаптивная политика хуже сильного порога

Не подтверждено

H4: иерархия представлений

504 260 объектов

Риск и средняя сложность

ГЛАВА 4	Метод реализации системного оператора	FuzzyXAI
---------	--	----------

Риск 0,7410; сложность 3,137 вместо 8

Подтверждено

H5-S: структурный разрыв

4 000 нарушений

F1 и локализация источника

F1 = 1,000; локализация = 1,000

Подтверждено

H5-P: предсказание ошибки

2 500 объектов

Прирост AUPRC

0,0000

Не подтверждено

H6: абляция правила

400 пар

Спец. эффект

−0,00042; ДИ включает ноль

Не подтверждено

Сравнение объяснителей

100–2 000 объектов

Верность, устойчивость, полнота, время

Метрики измерены без универсального победителя

Описательный результат

Анализ чувствительности

2 000 объектов

Смена действия и стоимость

Наибольшая чувствительность к порогу уверенности

Описательный результат

Масштаб

ГЛАВА 4	Метод реализации системного оператора	FuzzyXAI
---------	--	----------

1 000–100 000 объектов

Время, память, размер графа

Рост близок к линейному

Подтверждено для эталонного контура

Слепая AI-предпроверка

240 случаев, 720 вариантов

R1–R10 и критические дефекты

Выявлены пропущенные ограничения и термины

Только формирующий этап

Качественная пользовательская оценка

Участники, изучающие XAI

Понятность терминов, ограничений и действия

После доработки объяснения оценены как понятные и приемлемые

Проведено качественно

Таблица 4.10 задаёт полную карту главы: для каждого эксперимента указаны объект, размер, основная измеряемая величина, фактический результат и допустимый статус вывода. Автоматизированная предварительная проверка использовалась для поиска недостатков текста, после чего переработанные объяснения получили положительную качественную оценку участников, изучающих объяснимый искусственный интеллект.

В каждом контуре использованы классические и нейросетевые модели. Для табличных данных применялись линейная модель, ансамбль деревьев, градиентный бустинг и многослойная сеть; для изображений — свёрточная сеть; для текста — линейный классификатор и последовательная нейросетевая модель; для временных рядов — признаковая модель и одномерная нейросетевая архитектура. Одна из нейросетевых моделей

ГЛАВА 4	Метод реализации системного оператора	FuzzyXAI
---------	--	----------

экспортирована в ONNX, что подтверждает переносимость адаптера между средами исполнения.

Модальность	Метод	Число объяснений	Средняя локальная верность
Изображения	Grad-CAM	500	0,114
Изображения	Integrated Gradients	500	0,453
Табличные данные	SHAP	1 000	0,249
Табличные данные	LIME	1 000	0,200
Табличные данные	Anchors	1 000	0,910
Табличные данные	RuleFit	1 000	0,883
Текст	Маскирование токенов	500	0,279
Временные ряды	Маскирование окон	500	0,621

Таблица 4.11 — Методы объяснения и объём измерений

Рисунок 4.4 — Средняя измеренная локальная верность применённых объяснителей

Значения локальной верности в таблице 4.5 относятся к различным методам и типам данных, поэтому они не образуют универсального рейтинга. Их назначение состоит в фиксации качества исходного локального сигнала, который затем передаётся в системный слой. Сравнение N1 проводится парно: для одного объекта, одной модели, одного результата объяснителя, одной фоновой выборки, одинакового бюджета и случайного состояния.

$$\Delta_{\text{fid}} = \text{Kfid}(\text{FuzzyXAI} + \text{Base}) - \text{Kfid}(\text{Base}) \quad (4.6)$$

Гипотеза сохранения верности считается подтверждённой, если нижняя граница доверительного интервала для Δ_{fid} не ниже $-0,02$. Для оценки неполноты на реальных контурах выполнялось контролируемое удаление идентифицируемого канала происхождения. Такая процедура проверяет способность системы обнаружить известное нарушение, но не заменяет анализ всех возможных естественных сбоев.

Политики действия сравнивались на фиксированной выборке из 2 500 объясняемых объектов. Сложные случаи определялись по валидационной части как низкая уверенность, измеренное расхождение объяснителей, конфликт моделей, редкий класс или нахождение в фиксированной

ГЛАВА 4	Метод реализации системного оператора	FuzzyXAI
---------	--	----------

пограничной полосе. Тестовые исходы не использовались для определения этих групп.

В подтверждающей проверке абляции правила использованы два независимых табличных набора, четыре семейства моделей, десять разбиений и пять случайных состояний. Правило-кандидат выбиралось по обучающей и валидационной частям, после чего сравнивалось с сопоставимыми контрольными правилами. Основной показатель представляет разность между эффектом удаления выбранного правила и медианным эффектом сопоставимых контрольных правил.

$$\Delta_{\text{spec}} = \Delta_{\text{cand}} - \text{median}(\Delta_{\text{match}}) \quad (4.7)$$

Таким образом, методика разделяет качество исходного объяснения, структурную корректность маршрута и качество политики действия. Последующие разделы рассматривают эти свойства независимо, что исключает перенос положительного результата одного контура на другой.

4.4 Сохранение локальной верности и диагностика неполноты

В H1 выполнено 6 000 парных сравнений. Системная оболочка использовала готовый результат локального объяснителя как неизменяемое свидетельство; поэтому средняя разность локальной верности для всех методов равна нулю, а доверительный интервал имеет границы [0; 0]. Критерий неухудшения выполнен для всех восьми методов и четырёх модальностей.

Таблица 4.12 — Результат парной проверки сохранения локальной верности

Метод

Данные

Пар

Средняя разность

95%-й ДИ

ГЛАВА 4	Метод реализации системного оператора	FuzzyXAI
---------	--	----------

Не хуже

Grad- CAM

Изобр.

500

0,000

[0,000; 0,000]

Да

Integrated Gradients

Изобр.

500

0,000

[0,000; 0,000]

Да

SHAP

Табл.

1 000

0,000

[0,000; 0,000]

Да

LIME

Табл.

1 000

0,000

[0,000; 0,000]

Да

Anchors

Табл.

1 000

ГЛАВА 4	Метод реализации системного оператора	FuzzyXAI
---------	--	----------

0,000

[0,000; 0,000]

Да

RuleFit

Табл.

1 000

0,000

[0,000; 0,000]

Да

Токены

Текст

500

0,000

[0,000; 0,000]

Да

Окна

Врем. ряды

500

0,000

[0,000; 0,000]

Да

Полученный результат не означает превосходства системного оператора над локальными объяснителями. Он подтверждает более узкое, но необходимое свойство: включение локального результата в доказательный граф, типизация, диагностика и редукция не меняют исходную атрибуцию. Таким образом, вклад метода относится к организации объяснительного маршрута, а не к повышению внутренней верности подключённого объяснителя.

ГЛАВА 4	Метод реализации системного оператора	FuzzyXAI
---------	--	----------

В Н2 выполнено 2 000 контролируемых удалений каналов, по 500 на каждую модальность. Во всех случаях система обнаружила отсутствие и указала точный источник. Точность положительных решений, полнота и F1 составили 1,0; доля ложной сертификации равна нулю. Пользовательская редукция сохранила доступное происхождение полностью.

Таблица 4.13 — Локализация отсутствующих каналов происхождения

Данные

Удалений

Точность источника

Сохранение происхождения

Время, мс

Табличные

500

1,000

1,000

0,7274

Изображения

500

1,000

1,000

0,6694

Текст

500

1,000

1,000

0,6761

Врем. ряды

500

ГЛАВА 4	Метод реализации системного оператора	FuzzyXAI
---------	--	----------

1,000

1,000

0,6815

Совершенные показатели H2 следует интерпретировать в пределах протокола контролируемого внесения отказов. Удалялся канал с известной идентичностью в реально измеренном вычислительном контуре. Результат подтверждает корректность реализованного контракта неполноты для предусмотренных типов каналов, но не доказывает обнаружение любого неизвестного сбоя внешней системы.

Совместное подтверждение H1 и H2 показывает, что системная надстройка не обязана повышать локальную верность, чтобы давать самостоятельный результат. Её измеримый вклад состоит в сохранении исходного объяснения, добавлении происхождения и явном различии отсутствия данных и измеренного нулевого значения.

Совместное подтверждение H1 и H2 устанавливает базовый инвариант реализации: системная надстройка сохраняет исходное объяснение и одновременно делает отсутствие обязательных сведений наблюдаемым состоянием.

4.5 Экспериментальная проверка иерархии представлений неопределённости

Гипотеза H4 проверялась на измеренных профилях 504 260 объектов. Для каждого объекта определялся минимальный класс представления, способный покрыть доступные типы неопределённости. Сравнивались постоянный выбор F0, Fint, NAS, FML, адаптивный выбор и диагностический отказ.

Режим	Покр.	Недоп.	Сложн.	Риск	Стоим.
F0	0,3612	0,6388	1,000	0,8510	6,749
Fint	0,3612	0,4412	2,000	0,8510	6,749
NAS	0,6484	0,1539	4,000	0,7410	4,164
FML	0,6484	0,0000	8,000	0,7410	4,164

ГЛАВА 4		Метод реализации системного оператора		FuzzyXAI	
Режим	Покр.	Недоп.	Сложн.	Риск	Стоим.
Адапт.	0,6484	0,0000	3,137	0,7410	4,164
Отказ	0,0000	0,0000	0,500	1,0000	10,000

Таблица 4.14 — Сравнение режимов представления неопределённости

Рисунок 4.5 — Соотношение сложности представления и риска действия

Постоянные F0 и Fint имеют риск 0,8510 и существенное недопокрытие. NAS уменьшает риск до 0,7410, но оставляет недопокрытие 0,1539. Постоянный выбор FML устраняет недопокрытие при средней сложности 8. Адаптивный режим имеет тот же риск 0,7410 и нулевое недопокрытие, но уменьшает среднюю сложность до 3,137.

В адаптивном режиме F0 выбран для 182 122 объектов, Fint — для 99 668, NAS — для 144 856, FML — для 77 614. Доля FML составляет 0,1539, поэтому селектор не вырождается в постоянный выбор наиболее сложного класса. Критерий неухудшения относительно постоянного выбора FML выполнен при $\varepsilon = 0,02$.

$$R_{\text{adapt}} \leq R_{\text{FML}} + 0,02; C_{\text{adapt}} < C_{\text{FML}} \quad (4.8)$$

Научный результат Н4 состоит не в предложении нового класса нечётких множеств. Новизна относится к операциональной процедуре выбора минимально достаточного представления при совместном ограничении на покрытие, риск и сложность. Эксперимент показывает, что использование наиболее выразительного класса для каждого объекта избыточно в измеренных профилях.

Граница вывода определяется способом формирования профилей. Часть признаков неопределённости возникает из реальных измерений уверенности, расхождения и нестабильности, а часть структурных нарушений вносится контролируемо. Поэтому вывод относится к реализованному множеству профилей и функции риска и не

ГЛАВА 4	Метод реализации системного оператора	FuzzyXAI
---------	--	----------

распространяется автоматически на любые предметные типы неопределённости.

После подтверждения сохранности и неполноты следующий вопрос относится к сложности представления: можно ли уменьшить объём объяснительного объекта без изменения установленного риска.

Доказательная основа раздела: E02. Замороженная сводка фиксирует 504 260 объектов, снижение средней сложности с 8 до 3,137 и сохранение зарегистрированного риска.

4.6 Сравнение политик действия и границы практического эффекта

Гипотеза НЗ предполагала, что адаптивная политика действия сможет превзойти сильнейшую простую политику на всей выборке или на заранее определённых сложных случаях. Сравнивались безусловное принятие P0, два порога уверенности P1 и P2, эвристика расхождения объяснителей P3, правило конфликта P4, полный анализ P5, случайная эскалация P6, адаптивная политика P7 и аналитический ориентир P8.

Коды политик используются для компактного представления результатов: P0 — безусловное принятие, P1 и P2 — пороги уверенности 0,70 и 0,75, P3 — расхождение объяснителей, P4 — конфликт моделей или редкого класса, P5 — полный анализ, P6 — случайная эскалация, P7 — адаптивная политика, P8 — аналитический ориентир.

Код	Покрытие	Риск	Ошибочных автоматических	На проверку	Стоимость
P0	1,0000	1,6460	823	0	1,000
P1	0,4512	0,8828	167	1372	1,100
P2	0,3676	0,8584	113	1581	1,300
P3	0,4708	1,4672	469	1323	2,500
P4	0,6608	1,0052	333	848	1,500
P5	0,1596	0,9724	66	2101	10,000
P6	0,1596	1,1124	136	2101	8,564
P7	0,1596	0,9724	66	2101	8,564
P8	0,6708	0,3292	0	823	10,000

ГЛАВА 4	Метод реализации системного оператора	FuzzyXAI
---------	--	----------

Таблица 4.15 — Сравнение политик на полной выборке из 2 500 объектов

Рисунок 4.6 — Риск и автоматическое покрытие политик на полной выборке

Минимальный риск среди простых реализуемых политик получен для P2 и равен 0,8584 при покрытии 0,3676. Адаптивная политика P7 имеет риск 0,9724 и покрытие 0,1596. Она уменьшает число ошибочных автоматических решений до 66, но достигает этого за счёт передачи 2 101 объекта на проверку и не превосходит сильную простую пороговую политику по принятому критерию.

На подмножестве из 2 101 заранее определённого сложного объекта результат сохраняется. Для P2 риск равен 0,9134, тогда как P7 переводит все сложные объекты на проверку и получает риск 1,0. Поэтому H3 не подтверждена ни на полной выборке, ни на заранее определённых сложных случаях. Полный системный контур не может быть представлен как универсально лучшая политика действия.

Отрицательный результат уточняет функцию метода. Системный оператор обеспечивает воспроизводимую диагностику и структурное ограничение действия, но оптимальная политика зависит от предметной стоимости ошибок и проверки. Простая калиброванная политика может быть предпочтительнее, если доступные системные сигналы не дают дополнительной селективной информации.

Причина отсутствия превосходства P7 видна из структуры решений. Объединение признаков низкой уверенности, редкого класса, близости к границе, расхождения моделей и объяснителей охватывает 2 101 из 2 500 объектов, то есть 84,04% выборки. В таком режиме политика теряет селективность и практически превращается в правило тотальной передачи на

ГЛАВА 4	Метод реализации системного оператора	FuzzyXAI
---------	--	----------

проверку. Порог уверенности P2, напротив, использует наиболее информативный модельный сигнал и сохраняет больше автоматического покрытия. Следовательно, происхождение, конфликт и нестабильность полезны как диагностические признаки, но в данном эксперименте не дали дополнительной селективной мощности для оптимизации действия.

В главе не формулируется утверждение о доказанном снижении ошибочных автоматических решений относительно сильного порога. Практическая польза политики должна проверяться в конкретной предметной области при заранее заданной стоимости ошибок и ручной проверки. Поскольку такое преимущество в настоящем эксперименте не установлено, H3 сохраняет статус «не подтверждена».

Результат H3 следует читать как границу практического эффекта, а не как отказ всей архитектуры: диагностические признаки оказались полезны для аудита, но не дали универсального селективного преимущества.

4.7 Критический разрыв и абляция правил

Критическим разрывом называется отсутствие допустимого сертифицируемого маршрута от обязательных свидетельств к автоматическому действию. В вычислительной реализации он типизирован по источнику нарушения: отсутствующее свидетельство, несовместимая версия, повреждённое происхождение, недопокрытие представления, превышение потери редукции и другие предусмотренные состояния.

$$\chi_{\text{crit}}(E)=1 \Leftrightarrow \text{не существует допустимого пути } V \rightarrow C \rightarrow \chi \quad (4.9)$$

Структурная проверка H5-S включала 4 000 внесённых нарушений, по 1 000 на каждую модальность. Точность положительных решений, полнота, F1, точность типа и локализация источника равны 1,0; ложная сертификация отсутствует. Среднее время обнаружения составляет 0,00063 мс. Результат подтверждает корректность структурного индикатора для реализованных классов нарушений.

ГЛАВА 4	Метод реализации системного оператора	FuzzyXAI
---------	--	----------

Таблица 4.16 — Результаты проверки критического разрыва

Режим

N

F1

Локал.

AUPRC M0 / M1

Статус

Структ.

4 000

1,000

1,000

—

Да

Предикт.

Тестовая выборка

—

—

0,5326 / 0,5326

Нет

Предсказательная гипотеза H5-P не подтверждена. Добавление признаков критического разрыва не изменило AUPRC модели риска: M0 и M1 имеют значение 0,5326. Следовательно, критический разрыв нельзя интерпретировать как самостоятельный предиктор ошибки или безопасности. Его назначение ограничивается проверкой структурной допустимости объяснительного маршрута.

Абляция правил проверялась относительно сопоставимых контрольных правил на 400 парных сравнениях. Средний специфический эффект равен $-0,00042$, а 95%-й доверительный интервал $[-0,07895; 0,07808]$ включает

ГЛАВА 4	Метод реализации системного оператора	FuzzyXAI
---------	--	----------

практически нулевую область $[-0,01; 0,01]$. В двух наборах получены противоположные эффекты: 0,1283 для Adult и $-0,1292$ для Covertype.

Рисунок 4.7 — Гетерогенность специфического эффекта исключения правила

Показатель	Значение
Число парных сравнений	400
Средний специфический эффект	-0,00042
95%-й доверительный интервал	$[-0,07895; 0,07808]$
Практически нулевая область	$[-0,01; 0,01]$
Эффект Adult	0,1283
Эффект Covertype	-0,1292
Итоговый статус	Не подтверждено

Таблица 4.17 — Подтверждающая проверка абляции правила

Противоположность эффектов показывает, что удаление правила не имеет общей направленности даже при предварительном выборе правила-кандидата. Поэтому абляция сохраняется как локальная диагностическая процедура конкретной модели, набора данных и разбиения. Утверждения об общем предсказательном эффекте или эффекте повышения безопасности удаления правила исключаются.

Структурный разрыв и ошибка прогноза далее рассматриваются отдельно. Это различие необходимо, поскольку корректный прогноз может иметь повреждённое происхождение, а ошибочный прогноз — полный и воспроизводимый маршрут.

4.8 Масштабируемость, воспроизводимость и статус технического выпуска

Масштабируемость оценивалась в двух режимах. Ранний эталонный маршрут до 100 000 объектов включал загрузку, уже доступные прогнозы и объяснительные признаки, операторную обработку и сериализацию. Отдельная H9 расширила измерение до 5 млн записей только для

ГЛАВА 4	Метод реализации системного оператора	FuzzyXAI
---------	--	----------

кэшированного операторного слоя. Стоимость внешней модели и тяжёлых методов SHAP, LIME или Grad-CAM в это измерение не включалась.

Ранний эталонный контур показал близкий к линейному рост времени и памяти до 100 000 объектов. Полные значения перенесены в таблицу А.1; основное итоговое измерение до 5 млн записей приведено далее в разделе Н9.

Размер доказательного графа и сериализованного представления также рос близко к линейному. Полные строки приведены в таблице А.2.

Рисунок 4.8 — Изменение времени и памяти при увеличении числа объектов

Для 1 000 объектов полный измеренный маршрут занимает 0,0098 с и использует 0,65 МБ пиковой памяти; для 100 000 объектов — 0,8656 с и 63,7 МБ. Время и память растут близко к линейной зависимости для данного эталонного контура. Основная доля накладных расходов связана с формированием пользовательского текста и сериализацией, а не с построением самого графа.

Публичные режимы интерфейса дополнительно проверены для одного объекта, пакетов из 100 и 1 000 объектов, глобального объяснения и сравнения моделей. Пакет из 1 000 объектов формируется за 4,97 с. Эти значения характеризуют эталонную конфигурацию и не включают произвольную стоимость внешнего тяжёлого объяснителя, которая должна измеряться отдельно.

Воспроизводимость обеспечивается фиксированными версиями библиотек, контрольными суммами данных и моделей, списками идентификаторов объектов, контейнерной сборкой и автоматическим формированием таблиц и отчётов. Итоговая техническая версия прошла

ГЛАВА 4	Метод реализации системного оператора	FuzzyXAI
---------	--	----------

публичную автоматизированную проверку, чистое контейнерное воспроизведение и проверку внутренних контрольных сумм архивов.

Гипотеза	Статус	Разрешённая интерпретация
H1	Подтверждено	Системная оболочка сохраняет локальную верность подключённого объяснителя
H2	Подтверждено	Предусмотренные отсутствующие каналы локализуются без ложной сертификации
H3	Не подтверждено	Адаптивная политика не превосходит сильную простую пороговую политику
H4	Подтверждено	Адаптивное представление снижает сложность при не худшем риске
H5-S	Подтверждено	Критический разрыв является структурным индикатором
H5-P	Не подтверждено	Предсказательный эффект критического разрыва отсутствует
H6	Не подтверждено	Абляция правила используется только как локальная диагностика
Качественная оценка объяснений	Проведена	Переработанные формулировки признаны понятными участниками, изучающими XAI; количественный эффект не оценивался

Таблица 4.18 — Итоговый статус экспериментальных гипотез

Технический выпуск v1.3.0 фиксирует воспроизводимые вычислительные свойства реализации. Его стабильный статус относится к коду, контрактам и замороженным артефактам и не трактуется как подтверждение предметной безопасности или универсального преимущества политики применения.

Полученные результаты задают первую доказательную линию. Далее методы сопоставляются на общих объектах, а статистические выводы проверяются повторными разбиениями и доверительными интервалами.

4.9 Количественное сопоставление с локальными объяснителями и простыми базовыми схемами

Критика поверхностного сравнения снимается только отдельным рассмотрением двух задач. На четырёх реальных контурах измерена исходная локальная верность каждого применимого объяснителя и затем выполнена парная проверка её сохранения системной оболочкой. На

ГЛАВА 4	Метод реализации системного оператора	FuzzyXAI
---------	--	----------

отдельном контролируемом табличном контуре методы SHAP, LIME, Anchors и RuleFit сопоставлены с простыми эвристиками и вариантами FuzzyXAI по верности, устойчивости, полноте, разреженности и времени. Эти две таблицы нельзя объединять в универсальный рейтинг: наборы данных, смысл объяснения и число оцениваемых объектов различаются.

Раннее сопоставление подтвердило отсутствие универсального победителя и сохранение метрик исходного объяснителя системным слоем. Полные строки приведены в таблице A.3; агрегированное сравнение независимого контура дано в разделе 4.16.

Рисунок 4.9 — Верность и полнота методов на общем контролируемом контуре

Anchors и RuleFit имеют более высокие значения измеренной верности на данном контуре, но отличаются формой результата, разреженностью и вычислительной стоимостью. FuzzyXAI поверх того же локального объяснителя полностью сохраняет его метрики. Полный вариант, использующий SHAP и LIME, имеет верность 0,2749, устойчивость 0,9977 и полноту 0,8450; он не превосходит Anchors или RuleFit по локальной верности. Следовательно, научный вклад системного оператора нельзя формулировать как универсальное улучшение локальной атрибуции.

Простая эвристика расхождения SHAP/LIME и полный FuzzyXAI имеют одинаковые локальные показатели в этом эксперименте, поскольку используют один и тот же набор атрибуций. Отличие системного варианта состоит в типизации неполноты, происхождении утверждений, выборе представления и формировании действия. Сама по себе структурная надстройка не считается доказанным преимуществом политики; соответствующая гипотеза НЗ проверяется отдельно и не подтверждается.

ГЛАВА 4	Метод реализации системного оператора	FuzzyXAI
---------	--	----------

На реальных данных подтверждено не превосходство, а неухудшение: в 6 000 парных сравнениях системный слой не изменил значение локального объяснения. Такая постановка устраняет некорректное требование сделать системную оболочку лучше метода, который она принимает как неизменяемый источник свидетельств.

Ранний контролируемый эксперимент не подтвердил превосходство системной политики над простым порогом уверенности. Полная матрица действий и стоимости приведена в таблице А.4.

На контролируемом контуре минимальная средняя стоимость при сбалансированном сценарии получена у простого порога уверенности и равна 0,8793. Системные политики Р4 и Р5 имеют стоимость 1,1395, автоматически принимают 49,2% объектов, направляют 996 объектов на проверку и дают 18 ложных блокировок. Поэтому таблица А.4 не подтверждает превосходство FuzzyXAI над простыми эвристиками; она показывает цену добавления структурных ограничений.

F1 действия в таблице А.4 намеренно не приводятся. Для его вычисления необходим независимый эталон того, какое действие действительно должен выбрать специалист. Контролируемый структурный контракт задаёт только внесённые нарушения и стоимость, но не заменяет экспертный золотой стандарт. Подстановка прокси-метки в качестве экспертного решения создала бы ложное подтверждение.

Описательные различия сами по себе недостаточны для научного вывода. Поэтому следующий раздел оценивает устойчивость эффектов относительно повторных разбиений и множественных сравнений.

4.10 Повторные разбиения, доверительные интервалы и статистические проверки

Статистическая проверка проводилась на нескольких уровнях. Первичная абляция правила использовала десятикратное разбиение и пять

ГЛАВА 4	Метод реализации системного оператора	FuzzyXAI
---------	--	----------

независимых случайных состояний, то есть 50 парных сравнений. Финальный подтверждающий протокол расширил проверку до двух реальных наборов, четырёх семейств моделей, десяти разбиений и пяти случайных состояний, что дало 400 парных сравнений. Политики действия оценивались на фиксированной совокупности из 2 500 объектов с парным bootstrap по объектам.

Повторная проверка на 50 парных сравнениях не выявила практически значимого общего эффекта удаления правила. Полная статистика вынесена в таблицу А.5.

Точный критерий Мак-Немара для объединённых предсказаний дал 52 случая, где верна только базовая модель, и 46 случаев, где верна только модель после удаления правила; $p = 0,6137$. Даже статистически различимая разность полноты имеет величину около 0,0014 и не образует практически значимого общего эффекта. Поэтому первичный результат рассматривается как иллюстрация чувствительности конкретного правила, а не как доказательство общей закономерности.

Проверка	N	Эффект и 95%-й ДИ	p	Вывод
НЗ, все	2 500	Риск P7 – P2 = 0,1140; ДИ [0,0684; 0,1604]	< 0,001	P7 хуже
НЗ, сложные	2 101	Риск P7 – P2 = 0,0866; ДИ [0,0414; 0,1304]	0,0006	P7 хуже
Н5-Р	2 500	AUPRC M1 – M0 = 0,0000; ДИ [0,0000; 0,0000]	1,000	Прироста нет
Н6	400	$\Delta \text{спес} = -0,00042$; ДИ [-0,07895; 0,07808]	Разные знаки	Нет общего эффекта

Таблица 4.19 — Сводная статистическая проверка НЗ, Н5-Р и Н6

Для Н6 поправка Холма применена к двум заранее зафиксированным репликациям. На Adult получен положительный эффект 0,1283 с скорректированным $p < 0,00001$, а на Coverttype — отрицательный эффект $-0,1292$. Противоположные знаки не позволяют объявить общий результат, даже если одна отдельная репликация статистически значима. Такой вывод

ГЛАВА 4	Метод реализации системного оператора	FuzzyXAI
---------	--	----------

важнее механического требования получить $p < 0,05$: статистическая значимость не заменяет воспроизводимость направления и практический размер эффекта.

Статистическая проверка определяет наличие эффекта, но не показывает, насколько результат зависит от выбранных порогов и входных возмущений. Этот вопрос рассматривается далее.

4.11 Анализ чувствительности действий к параметрам и входным возмущениям

Анализ чувствительности выполнен относительно калиброванных значений порога уверенности 0,65, порога конфликта 0,10 и порога устойчивости 0,55. Каждый параметр изменялся с множителями 0,50; 0,75; 1,00; 1,25 и 1,50 при фиксированных остальных параметрах. Для каждого значения измерялись доли действий, средняя стоимость, число ложных блокировок и доля объектов, у которых изменилось действие.

Параметр	Множитель	Порог	Доля смены действия	Средняя стоимость
Увер.	0,50	0,325	0,2345	1,1898
Увер.	0,75	0,488	0,2345	1,1898
Увер.	1,00	0,650	0,0000	1,1395
Увер.	1,25	0,812	0,2240	1,2035
Увер.	1,50	0,975	0,4695	1,4757
Конфл.	0,50	0,050	0,0000	1,1395
Конфл.	0,75	0,075	0,0000	1,1395
Конфл.	1,00	0,100	0,0000	1,1395
Конфл.	1,25	0,125	0,0000	1,1395
Конфл.	1,50	0,150	0,0000	1,1395
Уст.	0,50	0,275	0,1805	0,9527
Уст.	0,75	0,413	0,0915	1,0582
Уст.	1,00	0,550	0,0000	1,1395
Уст.	1,25	0,688	0,0920	1,2215
Уст.	1,50	0,825	0,2285	1,3082

Таблица 4.20 — Чувствительность действий к калиброванным параметрам

ГЛАВА 4	Метод реализации системного оператора	FuzzyXAI
---------	--	----------

Рисунок 4.10 — Доля объектов со сменой действия при изменении порогов

Наиболее чувствительным параметром является порог уверенности: при увеличении в 1,5 раза действие меняется для 46,95% объектов. В исследованном диапазоне изменение порога конфликта не изменило действие, что указывает на отсутствие активной границы по этому параметру в данной выборке. Изменение порога устойчивости приводит к смене действия для 9,15–22,85% объектов в зависимости от направления отклонения. Средняя робастность действия K_{rob} равна 0,883, минимальное значение по объектам — 0,733.

Сценарий	Доля изменившихся прогнозов
Шум признаков	0,0180
Пропуски с медианным заполнением	0,0275
Сдвиг распределения	0,0850
Смена фоновой выборки	0,0055

Таблица 4.21 — Чувствительность прогноза к входным возмущениям

Максимальная доля изменившихся прогнозов наблюдается при сдвиге распределения и составляет 0,085. Результат не означает универсальной устойчивости модели: он характеризует конкретные интенсивности возмущений, определённые экспериментальным протоколом. Анализ чувствительности показывает области параметрической устойчивости и не используется для выбора новых порогов по тестовой части.

Измеренная устойчивость локальных объяснений составила 0,9977 в предусмотренном протоколе, но отдельная устойчивость набора правил не оценивалась. Полная детализация приведена в таблице А.6.

Измеренная устойчивость SHAP, LIME и совмещённого контура равна 0,9977 в предусмотренном протоколе повторных запусков. Это не позволяет автоматически утверждать, что топ-3 причины сохраняются при любом входном шуме. Специальный эксперимент с Jaccard для уровней $\sigma = 0,05$ и $\sigma = 0,20$ в доказательном архиве отсутствует; поэтому предлагаемые значения

ГЛАВА 4	Метод реализации системного оператора	FuzzyXAI
---------	--	----------

0,89 и 0,72 в главу не включаются. Таблица А.6 отделяет реально измеренное свойство от ещё не выполненной проверки.

Анализ чувствительности показывает локальные области устойчивости параметров. Отдельно необходимо проверить, сохраняет ли выбор минимально достаточного класса то же действие, что и наиболее полное представление.

4.12 Влияние класса представления неопределённости на действие

Иерархия представлений проверена не только по средней сложности, но и по результатам действия для каждого из 504 260 объектов. Постоянные режимы сопоставлены с FML на одних и тех же объектах. Адаптивный селектор выбирает минимальный класс, покрывающий измеренный профиль, поэтому его действие должно совпадать с FML, если снижение сложности не приводит к недопокрытию.

Режим	Принято в обоих	Проверка в обоих	Проверка → принятие	Изменено	Доля
F0	182122	177282	144856	144856	0,2873
Fint	182122	177282	144856	144856	0,2873
NAS	326978	177282	0	0	0,0000
adaptive	326978	177282	0	0	0,0000

Таблица 4.22 — Перекрёстное сопоставление действий с постоянным FML

При принудительном использовании F0 или Fint вместо FML действие меняется у 144 856 объектов: недостаточное представление переводит их из автоматического принятия в проверку. NAS и адаптивный режим полностью совпадают с FML по действиям на измеренной совокупности. Для адаптивного режима это не отсутствие эффекта иерархии, а ожидаемый критерий корректности: селектор снижает среднюю сложность с 8 до 3,137, сохраняя действие более полного представления для всех 504 260 объектов.

ГЛАВА 4	Метод реализации системного оператора	FuzzyXAI
---------	--	----------

Следовательно, влияние иерархии проявляется в двух формах. Недостаточно выразительный класс способен изменить действие из-за недопокрытия; минимально достаточный адаптивный класс сохраняет действие FML без его постоянной вычислительной сложности и сложности представления. Научный результат Н4 относится именно к сохранению действия при снижении сложности, а не к обязательной смене действия адаптивным селектором.

Совпадение действий адаптивного режима с FML подтверждает корректность редукции, но не заменяет анализа исходов на всей выборке. Поэтому далее рассматриваются верные и ошибочные автоматические решения и нагрузка на проверку.

4.13 Статистика действий на всей исследованной выборке

Единичный сквозной пример используется только для демонстрации маршрута и не является статистическим доказательством. Основной анализ действий выполнен на всей фиксированной совокупности из 2 500 объектов четырёх реальных контуров. В таблице сопоставлены сильнейшая простая пороговая политика P2 и адаптивная политика P7.

Политика	Принято верно	Принято ошибочно	Передано на проверку, прогноз верен	Передано на проверку, прогноз ошибочен	Всего
P2, порог 0,75	806	113	871	710	2 500
P7, адаптивная	333	66	1344	757	2 500

Таблица 4.23 — Матрица исходов действий на полной реальной выборке

Рисунок 4.11 — Распределение исходов действий для P2 и P7

P7 уменьшает число ошибочно принятых объектов с 113 до 66, но одновременно увеличивает число объектов, направленных на проверку, с 1 581 до 2 101. При принятой функции стоимости это приводит к большему риску. Поэтому уменьшение абсолютного числа автоматических ошибок

ГЛАВА 4	Метод реализации системного оператора	FuzzyXAI
---------	--	----------

нельзя само по себе объявлять практическим превосходством без учёта покрытия и стоимости проверки.

Показатель	Значение
Принять	5 667
Проверить	4 328
Блокировать	5
Точность	0,7716
AUROC	0,8556
F1	0,7750
Ожидаемая калибровочная ошибка	0,0114
Доля критического разрыва	0,00050

Таблица 4.24 — Распределение действий и качество модели на полном контролируемом контуре из 10 000 объектов

Все пять блокировок в контролируемом контуре относились к правильным прогнозам и поэтому являются ложными блокировками относительно истинной метки. Этот результат дополнительно запрещает интерпретировать блокировку как доказательство ошибки модели. Структурный разрыв указывает на нарушение маршрута, а не на неправильность прогноза.

Матрица исходов показывает, что структурная блокировка и ошибка прогноза не тождественны. Воспроизводимость этих выводов требует отдельной фиксации данных, версий, команд и контрольных сумм.

4.14 Воспроизводимость и редакционная апробация формы объяснений

Воспроизводимость вычислительных результатов обеспечивается фиксацией версий кода, конфигураций, входных идентификаторов, случайных состояний и контрольных сумм артефактов. Числовые результаты главы связаны с машинно-читаемой картой доказательств; подробные пути, статусы и SHA256 вынесены в приложение.

Материалы проходили качественную редакционную апробацию специалистами, знакомыми с тематикой объяснимого искусственного интеллекта. Замечания использовались для уточнения терминологии,

ГЛАВА 4	Метод реализации системного оператора	FuzzyXAI
---------	--	----------

отделения вычислительного факта от интерпретации и более явного описания ограничений. Индивидуальные анкеты, количественный протокол, контрольная группа и статистика согласия не сохранялись. Поэтому апробация не используется для подтверждения гипотез о понятности, правильности действий или предметной безопасности.

Для будущего количественного исследования подготовлен отдельный протокол с критериями включения, рандомизацией, базовым условием, заданиями на понимание ограничений и планом статистического анализа. В настоящей главе он рассматривается только как направление дальнейшей работы.

4.15 Независимый подтверждающий контур и доказательная линия v1.3.0

Настоящий раздел дополняет первоначальную многомодальную программу главы независимым контуром, сформированным после фиксации результатов Н1–Н6. Он не заменяет прежние эксперименты и не переименовывает отрицательные гипотезы. Его назначение состоит в проверке новых, более узких утверждений Н3-Р1–Н3-Р4, Н5-А, Н6-А, Н6-В, Н7-А, Н7-В, Н8 и Н9 на новой доказательной линии.

Общие ограничения новых экспериментов. Н5-А относится к зарегистрированной библиотеке контролируемых нарушений, Н6-А — к синтетической области обнаружимости, Н8 — к анализу чувствительности без целевых меток, Н9 — к одному окружению и кэшированному операторному слою без стоимости исходного объяснителя. Ни один из этих результатов не переносится автоматически на неизвестные производственные сбои, реальные правила вне заданной области, универсальную устойчивость объяснений или полный сквозной конвейер.

ГЛАВА 4	Метод реализации системного оператора	FuzzyXAI
---------	--	----------

Хронология имеет методологическое значение. Ранний выпуск e34e52f фиксировал многомодальные результаты; ветка 1f5fd77 подготовила слепую автоматизированную проверку текста; технический выпуск v1.3.0 закрепил код и артефакты. Последующая качественная оценка переработанных объяснений людьми, изучающими объяснимый искусственный интеллект, относится к документальной апробации представления и не изменяет замороженные экспериментальные результаты.

Последовательность выпусков сохранила ранние отрицательные результаты и отделила техническую готовность от качественной оценки пользовательского представления. Полная линия версий приведена в таблице А.9.

4.15.1 Независимые данные, разделения и контроль утечек

Дополнительный контур включает пять независимых наборов четырёх модальностей: Bank Marketing [24], Default of Credit Card Clients [25], Shoulder Implant X-Ray [26], SMS Spam Collection [27] и UCI HAR Smartphones [28]. Суммарно сформировано 69 827 объектов, полученных вне обучающей складки (OOF) для обучения и разработки и 17 404 объекта контрольной выборки. Пересечение идентификаторов между этими частями равно нулю.

Набор данных	Модальность	OOF-выборка	Контрольная выборка
Bank Marketing	Табличные данные	32 940	8 236
Default of Credit Card Clients	Табличные данные	23 999	6 001
Shoulder Implant X-Ray	Изображения	477	120
SMS Spam Collection	Текст	4 127	1 032
UCI HAR Smartphones	Временные ряды	8 284	2 015
Всего	4 модальности	69 827	17 404

Таблица 4.25 — Состав независимого экспериментального контура v1.3.0

ГЛАВА 4	Метод реализации системного оператора	FuzzyXAI
---------	--	----------

Рисунок 4.12 — Распределение объектов между OOF- и контрольной выборками

Контроль повторов выполнялся по содержимому, а не только по строковым идентификаторам. Для изображений использовались кластеры перцептивно близких дубликатов; текстовые сообщения группировались после нормализации и MinHash-сопоставления; временные окна UCI HAR разделялись по субъектам. OOF-признаки строились перекрёстным обучением, а контрольные метки хранились в изолированном хранилище и не использовались при настройке.

Предварительный реестр до фиксации протокола содержал значения 69 825 и 17 406. После повторной группировки с учётом содержимого два объекта изменили роль. В итоговой редакции используются только окончательные значения 69 827 и 17 404; расхождение сохранено в аудиторском следе, а не скрыто.

4.15.2 Архитектура и протокол подтверждения

Практический контур разделён на семь уровней: прогноз, исходное объяснение, канонические свидетельства, предсказательный риск P0, риск маршрута и объяснения P1, жёсткая структурная проверка и формирование действия с аудиторским следом. Такое разделение не позволяет смешать исходную атрибуцию с её пользовательской проекцией и локализует уровень, на котором возникло ограничение.

Слой	Назначение	Проверяемый инвариант
Прогноз	Результат и оценка уверенности модели	Зафиксирована версия модели
Исходное объяснение	Локальные вклады признаков, токенов, областей или окон	Использован применимый к модальности метод
Канонический артефакт	Неизменяемая сериализация исходного объяснения	Хэш совпадает с исходным артефактом
P0	Оценка риска по предиктивным признакам	Используются только OOF-наблюдаемые величины
P1	Дополнительные признаки объяснения и маршрута	Отсутствующие каналы отмечаются явно
Структурная проверка	Контроль версий, схем и происхождения	Блокировка только по формальному нарушению

ГЛАВА 4	Метод реализации системного оператора	FuzzyXAI
Слой	Назначение	Проверяемый инвариант
Действие и аудит	Режим применения и журнал причин	Детерминированное повторное воспроизведение

Таблица 4.26 — Слои независимого практического контура и проверяемые инварианты

Рисунок 4.13 — Архитектура независимого объяснительно-аудиторского контура

До открытия контрольных меток были зафиксированы основной показатель, бюджет ручной проверки 20 %, профиль стоимости unsafe_accept_sensitive, предел ложных блокировок 0,01, набор базовых политик и статистические процедуры. Первоначальный расчёт итоговых метрик был признан недействительным из-за ошибки чтения внешнего контейнера меток. Прогнозы, объяснения, канонические артефакты, признаки R0/P1 и действия политик к этому моменту уже были сохранены и хэшированы без доступа к меткам. Итог получен восстановлением только этапа расчёта метрик без повторного обучения и настройки; протокольное отклонение раскрывается явно и не представляется как идеальный однократный запуск.

Независимый контур задаёт общую основу для сопоставления, однако сравнивать допустимо только методы одного функционального уровня.

Доказательная основа раздела: E01, E03–E10. Эти источники фиксируют линию выпуска, состав данных, аудит утечек, признаки, протокол, исходный недействительный маркер и заявленное восстановление расчёта метрик.

4.16 Корректное сопоставление локальных объяснителей, интерпретируемых моделей и политик

После фиксации данных и протокола требуется разделить методы по их фактической роли. Без этого локальные объяснения, самостоятельные модели

ГЛАВА 4	Метод реализации системного оператора	FuzzyXAI
---------	--	----------

и политики применения оказываются в одной таблице, хотя отвечают на разные научные вопросы.

Для корректного сопоставления методы разделены по объекту оценки. SHAP, LIME и Anchors рассматриваются как локальные постмодельные объяснители одной зафиксированной модели. GAM, EBM, RuleFit, разреженные деревья и списки правил оцениваются как самостоятельные интерпретируемые предикторы. Политики уверенности, конформного отбора и P0/P1 сравниваются как способы выбора режима применения. Объединение этих трёх семейств в один рейтинг методологически некорректно, поскольку они решают разные задачи и требуют разных показателей.

Семейство	Предмет сравнения	Основные показатели	Примеры методов
Локальные объяснители	Объяснения одной и той же модели	Верность, полнота, устойчивость, время	SHAP, LIME, Anchors, Integrated Gradients, Grad-CAM
Интерпретируемые предикторы	Самостоятельные модели	AUROC, Brier, сложность, время	GAM, GA ² M/FAST, EBM, RuleFit, дерево, список правил
Политики применения	Отбор объектов для автоматического решения	Покрытие и операционный риск	Порог уверенности, конформная политика, P0, P1

Таблица 4.27 — Таксономия допустимых сравнений

4.16.1 Локальные постмодельные объяснители

SHAP, LIME и Anchors сопоставлялись на одной и той же модели по верности удаления, полноте первых компонентов, устойчивости и времени. Компонентное исключение использовалось как модально нейтральная процедура. Значения через косую черту относятся к двум независимым подтверждающим табличным наборам и не образуют рейтинг между модальностями.

Метод	Верность удаления	Полнота первых пяти	Устойчивость	Время, с
SHAP	0,1460 / 0,1093	0,8321 / 0,6734	0,6488 / 0,8750	2,2921 / 0,0011
LIME	0,1496 / 0,1013	0,5188 / 0,5641	0,4687 / 0,4139	0,3997 / 0,2960
Anchors	0,1596 / 0,1230	0,9816 / 1,0000	0,4241 / 0,1413	10,8930 / 12,6818
Компонентное исключение	0,1292 / 0,1188	0,8314 / 0,6800	0,9917 / 0,9833	0,0016 / 0,0012

ГЛАВА 4	Метод реализации системного оператора	FuzzyXAI
---------	--	----------

Таблица 4.28 — Описательное сравнение локальных объяснителей на независимых табличных контурах

Рисунок 4.14 — Полнота и устойчивость локальных объяснений

Правиловые объяснения и атрибуции имеют разные объекты устойчивости. Для SHAP и LIME измеряется совпадение компонент и рангов; для наборов правил необходимо отдельно оценивать совпадение условий, покрытия, знака и состава правил. В замороженной доказательной базе единый эксперимент по устойчивости правил отсутствует. Поэтому утверждение о превосходстве устойчивости правил над SHAP и LIME в главу не вводится; отсутствие измерения фиксируется как граница и не заполняется вымышленным числом.

4.16.2 Современные интерпретируемые предикторы

GAM [21], GA²M с алгоритмом FAST [22], Explainable Boosting Machine [23], RuleFit [4], разреженное дерево и список правил рассматриваются как прямые аналоги на уровне интерпретируемого предиктора. FAST в данном контексте является алгоритмом ранжирования парных взаимодействий для GA²M, а не отдельным локальным объяснителем. FuzzyXAI не заменяет прогнозную функцию этих моделей и потому сопоставляется с ними по качеству прогноза, сложности и полноте аудита, но не объявляется «лучшей моделью».

Модель	AUROC	Brier	Сложность	Время, с
Градиентный black-box	0,7396 / 0,7611	0,0989 / 0,1407	Не зарегистрирована	0,2891 / 0,2283
GAM	0,8076 / 0,7661	0,1269 / 0,1878	129 / 114	0,0645 / 0,0655
EBM	0,8204 / 0,7743	0,0892 / 0,1363	30 / 23	0,8765 / 1,1618
RuleFit	0,8192 / 0,7733	0,0980 / 0,1571	29 / 27	35,7700 / 6,6061
Разреженное дерево	0,6844 / 0,7500	0,0960 / 0,1407	25 / 24	0,0170 / 0,0467
Список правил	0,6823 / 0,7475	0,0874 / 0,1409	6 / 6	0,0270 / 0,0539

Таблица 4.29 — Описательное сравнение интерпретируемых предикторов

ГЛАВА 4	Метод реализации системного оператора	FuzzyXAI
---------	--	----------

Рисунок 4.15 — Соотношение AUROC и зарегистрированной сложности интерпретируемых моделей

EBM и RuleFit дали наиболее высокие значения AUROC среди внутренне интерпретируемых моделей на двух табличных наборах, однако результаты не переносятся на необработанные изображения, текст и временные ряды. Основной вклад FuzzyXAI в этом сравнении относится не к качеству прогноза, а к унифицированному происхождению, каноническим свидетельствам, проверке маршрута и воспроизводимому формированию действия.

4.16.3 Политики применения

Четырнадцать политик сравнивались при одинаковом бюджете ручной проверки 20 %. Поэтому различия по числу недопустимых автоматических действий и операционному риску не объясняются различным объёмом проверки.

Политика	Покрытие	Недопустимые действия	Риск	Ложные блокировки
Всегда принимать	1,0000	4 172	0,2397	—*
Всегда проверять	0,0000	0	0,0000	—*
Порог уверенности	0,8000	2 811	0,1615	—*
Калиброванная уверенность	0,8000	2 806	0,1612	—*
Порог неопределённости	0,8000	2 840	0,1632	—*
Расхождение моделей	0,8000	2 923	0,1679	—*
Расхождение объяснителей	0,8000	3 307	0,1900	—*
Качество данных	0,8000	2 795	0,1606	—*
Полнота происхождения	0,8000	3 755	0,2158	—*
Логическое объединение	0,8000	3 089	0,1775	—*
Взвешенная политика	0,8000	2 722	0,1564	—*
Конформный отбор	0,8000	2 806	0,1612	—*
Риск прогноза P0	0,8000	2 839	0,1631	—*
Полный контур P1	0,8000	2 828	0,1625	—*

ГЛАВА 4	Метод реализации системного оператора	FuzzyXAI
---------	--	----------

Таблица 4.30 — Политики применения при фиксированном бюджете ручной проверки 20 %

После разделения аналогов проверяется главный практический вопрос: дают ли признаки происхождения и маршрута дополнительную пользу относительно сильных базовых политик.

Доказательная основа раздела: E15–E16. Таксономия и численные сравнения хранятся отдельно для постмодельных объяснителей, интерпретируемых предикторов и политик применения.

4.17 Практический контроллер и уточнённая проверка НЗ

Корректная таксономия позволяет перейти от качества объяснения к отдельному вопросу о практической политике: даёт ли системный слой дополнительный эффект при фиксированном бюджете проверки.

Первоначальная НЗ сохранена как неподтверждённая. В независимом контуре она была разложена на четыре заранее различимых утверждения: НЗ-Р1 — снижение числа операционно недопустимых автоматических действий при бюджете 20 %; НЗ-Р2 — прирост покрытия при фиксированном риске 0,05; НЗ-Р3 — дополнительная полезность признаков маршрута и объяснения относительно предсказательной политики Р0; НЗ-Р4 — полезность в заранее определённых группах неоднозначных случаев.

Полный Р1 сформировал 2 828 недопустимых автоматических действий, лучший зафиксированный базовый метод `'weighted_linear_score'` — 2 722, Р0 — 2 839. Следовательно, Р1 хуже лучшего базового метода на 106 событий. Относительная редукция $-0,038942$ имеет отрицательный знак, то есть число недопустимых действий увеличилось. Доверительный интервал и скорректированное р-значение не поддерживают превосходство.

ГЛАВА 4	Метод реализации системного оператора	FuzzyXAI
---------	--	----------

Рисунок 4.16 — Число недопустимых автоматических действий при фиксированном бюджете

Рисунок 4.17 — Кривые операционного риска и автоматического покрытия

Уточнённая НЗ не подтвердила преимущество P1 над лучшим базовым методом и предсказательной политикой P0. Полная таблица политик и исключения компонентов приведена в таблице A.10.

НЗ-P2 не оценивалась, поскольку на выборке разработки не существовало применимой рабочей точки с заранее заданной верхней границей риска 0,05. Изменение этой границы после открытия контрольной выборки означало бы смену основного показателя. НЗ-P3 не поддержана: различие P1 и P0 мало и не имеет устойчивого направления. В группе нестабильных объяснений наблюдалось локальное преимущество P1, однако заранее зафиксированная статистическая проверка подгруппы не была завершена, поэтому НЗ-P4 также не переводится в положительное утверждение.

На исследованных независимых наборах практический контроллер не продемонстрировал устойчивого преимущества над лучшими селективными базовыми политиками. Признаки маршрута и объяснения подтверждены как диагностические и аудиторские каналы, но не как универсальное средство повышения эффективности политики действия.

Отрицательный результат НЗ ограничивает функцию контроллера. Вместе с тем он не отвечает на вопрос, способен ли оператор сертифицировать структурную допустимость маршрута.

Доказательная основа раздела: E11–E14 и E24. В них зафиксированы итоговая статистика, сравнение P0/P1, исключение компонентов и заранее определённые группы неоднозначных случаев.

ГЛАВА 4	Метод реализации системного оператора	FuzzyXAI
---------	--	----------

4.18 Структурная валидность маршрута: H5-A без подмены H5-P

Неподтверждение практического преимущества не отменяет необходимости проверить более узкое свойство — способен ли оператор обнаружить формальную недопустимость маршрута независимо от истинности прогноза.

H5-S, H5-P и H5-A имеют разные целевые события. H5-S проверяет обнаружение зарегистрированного структурного разрыва, H5-P — связь разрыва с ошибкой модели, H5-A — допустимость автоматического маршрута при известных нарушениях контракта. Положительный H5-A не переименовывает и не отменяет отрицательный H5-P.

Библиотека H5-A включает 40 шаблонов нарушений и 14 композиционных шаблонов: отсутствие происхождения, несовпадение версии модели, неверная пара предобработки и объяснителя, отсутствие калибровки, неверная контрольная популяция, повреждённое преобразование, несовместимый словарь, чрезмерная потеря при редукции, повреждённая контрольная сумма аудита и другие зарегистрированные состояния. Итоговая совокупность содержит 1 950 записей.

Метод	Точность	Полнота	F1	Ложная сертификаци я	Локализация источника	Ложная блокировка
Логическое объединение	0,9848	0,1258	0,2231	0,8742	Не рассчитывала сь	0,0075
Типизированн ая проверка	1,0000	1,0000	1,0000	0,0000	1,0000	0,0000

Таблица 4.31 — Обнаружение и локализация контролируемых нарушений маршрута

Рисунок 4.18 — Сравнение простой и типизированной проверки маршрута

Типизированный валидатор получил точность, полноту, F1 и локализацию источника 1,0 при нулевой ложной сертификации и нулевой

ГЛАВА 4	Метод реализации системного оператора	FuzzyXAI
---------	--	----------

ложной блокировке. Простая дизъюнктивная проверка сохранила высокую точность, но имела полноту 0,1258 и ложную сертификацию 0,8742. Область вывода ограничена зарегистрированной библиотекой в соответствии с общими ограничениями раздела 4.15.

Структурная сертификация H5-A проверяет наличие маршрута, тогда как H6 оценивает обнаружимость и локальный эффект правил. Эти задачи не следует смешивать.

Доказательная основа раздела: E18–E19. Источники разделяют обнаружение зарегистрированных нарушений маршрута и отрицательный результат предсказательной H5-P.

4.19 Абляционный анализ: H6-A и H6-B при сохранении отрицательного H6-general

После проверки маршрута рассматривается другой диагностический объект — правило модели. Здесь необходимо отделить обнаружимость внедрённого эффекта от универсальной полезности удаления реального правила.

H6-general о едином воспроизводимом эффекте удаления важного правила остаётся неподтверждённой. Новые проверки отвечают на более узкие вопросы: H6-A исследует обнаружимость внедрённого эффекта в заранее зарегистрированной области применимости; H6-B переносит процедуру сопоставимого контроля на реальные правила двух табличных наборов.

H6-A подтвердила обнаружимость внедрённого эффекта только внутри заранее заданной области достаточной поддержки, эффекта и ограниченной избыточности. Полная факторная сетка приведена в таблице A.11.

Рисунок 4.19 — Доля обнаруженных правил в зависимости от поддержки и эффекта

ГЛАВА 4	Метод реализации системного оператора	FuzzyXAI
---------	--	----------

Область обнаружимости задана условиями: поддержка не ниже 0,05, внедрённый эффект не ниже 0,05 и избыточность не выше 0,50. Для 243 конфигураций доля обнаружения и правильность знака равны 1,0; точный 95 %-й биномиальный интервал Клоппера–Пирсона составляет [0,984934; 1,0]. Границы переноса результата определены общими ограничениями раздела 4.15.

Набор данных	Базовая точность	Эффект кандидата	Медиана контроля	Специфический эффект
Bank Marketing	0,7034	0,011656	0,000000	0,011656
Default Credit	0,8182	0,015331	0,007165	0,008165

Таблица 4.32 — Исключение реальных правил-кандидатов и сопоставимых контрольных правил Н6-В

Рисунок 4.20 — Наблюдаемый эффект исключения правил на двух независимых наборах

Направление специфического эффекта положительно на обоих наборах, но заранее зафиксированный доверительный интервал и критерий с поправкой Холма не были сформированы. Поэтому Н6-В имеет описательный статус и не считается статистическим подтверждением. Совокупный вывод остаётся прежним: абляция пригодна как локальная диагностика конкретной модели и правила, но не как универсальный механизм повышения качества.

Абляция определяет локальную чувствительность к правилу, но не гарантирует сохранность исходного объяснения при последующей редукции. Это свойство проверяется каноническим слоем Н7.

Доказательная основа раздела: E20–E21. Область обнаружимости внедрённых правил и результаты для реальных правил хранятся отдельно и имеют различный статус вывода.

ГЛАВА 4	Метод реализации системного оператора	FuzzyXAI
---------	--	----------

4.20 Канонический слой доказательств и пользовательская проекция: Н7

Диагностика правил и маршрута имеет смысл только при сохранении исходного объяснительного материала. Поэтому далее отдельно проверяются неизменность канонического слоя и свойства его сокращённой проекции.

Н7 разделяет исходный объяснительный артефакт и его сокращённую пользовательскую проекцию. Канонический слой хранит идентификатор компонента, знак, величину, ранг, условия правила или маску, параметры объяснителя, идентификатор контрольной выборки и SHA256. Группировка и текстовое сокращение создают отдельный производный объект и не изменяют исходные свидетельства.

Показатель	Значение	Научная интерпретация
Канонические артефакты	17 404	Полная контрольная выборка
Совпадение контрольных сумм	1,0000	Исходное объяснение сохранено точно
Сохранённая масса атрибуций	0,8382	Описательная характеристика проекции
Сокращение длины	0,7589	Проекция стала короче
Устойчивость исходного артефакта	0,8913	Не является приростом после проекции
Прирост устойчивости проекции	Не измерен	Улучшение не подтверждено

Таблица 4.33 — Сохранение канонических артефактов и характеристики пользовательской проекции

Рисунок 4.21 — Сохранение исходного объяснения и сокращение его проекции

Для 17 404 контрольных артефактов доля совпадения контрольных сумм равна 1,0, что подтверждает Н7-А. Средняя сохранённая масса атрибуций в проекции равна 0,8382, сокращение длины — 0,7589. Количественный прирост устойчивости или понимания после проекции не измерялся, поэтому Н7-В не подтверждена. Отдельная качественная оценка показала понятность переработанных формулировок, но не заменяет метрику Н7-В.

ГЛАВА 4	Метод реализации системного оператора	FuzzyXAI
---------	--	----------

Точное сохранение канонического артефакта не означает устойчивости его сокращённого отображения. Поэтому Н8 отдельно оценивает зависимость причин и действия от компонентной сетки.

Доказательная основа раздела: E22–E24. Каноническое сохранение и сокращённая проекция оцениваются как разные свойства; положительный Н7-А не переносится на неподтверждённую Н7-В.

4.21 Чувствительность объяснения к компонентной сетке: Н8

Сохранение канонического артефакта не гарантирует независимости отображаемых причин от гранулярности. Следующий эксперимент измеряет эту чувствительность непосредственно.

Анализ Н8 оценивает зависимость результата от гранулярности компонентного разбиения. Для изображений варьировалась сетка областей, для таблиц — группировка признаков, для текста — токены, фразы и группы, для временных рядов — длина и перекрытие окон. Сравнивались крупная, базовая, мелкая и очень мелкая сетки.

Модальность	Действие: К/М	Действие: ОМ	Класс: К/М	Класс: ОМ	Жаккар: вне Б
Изображения	1,0000 / 1,0000	0,9833	1,0000 / 1,0000	1,0000	0,0000
Табличные данные	0,9893 / 0,9937	0,9817	0,9121 / 0,9632	0,7203	0,0000
Текст	0,9942 / 0,9942	0,9826	0,9758 / 0,9845	0,8837	0,0000
Временные ряды	0,9950 / 0,9960	0,9911	0,9543 / 0,9742	0,8213	0,0000

Таблица 4.34 — Чувствительность действия и представления к компонентной сетке

Рисунок 4.22 — Согласованность действия, класса представления и состава первых компонентов

В диапазоне крупная–мелкая согласованность действия превышает 0,989 для табличных данных и 0,994 для текста и временных рядов; для изображений она равна 1,0. Очень мелкая сетка снижает согласованность представления до 0,7203 на таблицах, 0,8837 на тексте и 0,8213 на временных

ГЛАВА 4	Метод реализации системного оператора	FuzzyXAI
---------	--	----------

рядах. При этом коэффициент Жаккара для первых компонентов для всех небазовых конфигураций равен нулю. Следовательно, действие устойчивее состава отображаемых причин, а гранулярность обязана сохраняться в происхождении.

Н8 интерпретируется как анализ чувствительности без использования целевых меток. Результат задаёт область сопоставимости компонентных сеток, но не подтверждает универсальную устойчивость объяснения; общие ограничения приведены в разделе 4.15.

Чувствительность к сетке устанавливает границы сопоставимости объяснений. Последний вычислительный вопрос относится к стоимости самого операторного слоя при увеличении числа объектов.

Доказательная основа раздела: E25. Матрица фиксирует согласованность действия, класса представления и состава первых компонентов для четырёх модальностей и четырёх уровней гранулярности.

4.22 Масштабируемость кэшированного операторного слоя: Н9

После установления семантических границ оценивается вычислительная стоимость собственной части оператора, отделённая от стоимости исходных объяснителей.

Формула (4.5a) отделяет стоимость внешней модели и локального объяснителя от собственной операторной обработки. Поэтому результаты Н9 относятся к $T_FuzzyXAI$, а не к полному T_total .

Н9 разделяет стоимость исходного объяснителя и собственную стоимость операторного слоя. Измерение начинается после формирования локального объяснения; время SHAP, LIME, Grad-CAM или другого объяснителя не включается. Такое разделение предотвращает как приписывание чужой стоимости оператору, так и рекламное отождествление измерения только операторного слоя с полным конвейером.

ГЛАВА 4	Метод реализации системного оператора	FuzzyXAI
---------	--	----------

Н9 характеризует только кэшированный операторный слой после получения локального объяснения. Полный перечень условий, ограничений и измерительных оговорок приведён в таблице А.12.

Объекты	Время, с	Объектов/с	p50 / p95 / p99 пакета, мс	Peak RSS, байт
100 000	0,0137	7 282 846	1,3611 / 1,4309 / 1,4637	1 858 224 128
1 000 000	0,1362	7 341 473	1,3603 / 1,3827 / 1,3916	1 858 224 128
2 000 000	0,2730	7 324 936	1,3618 / 1,3860 / 1,4193	1 858 224 128
5 000 000	0,7196	6 948 453	1,3873 / 1,6303 / 2,0195	1 858 224 128

Таблица 4.35 — Производительность кэшированного операторного слоя

Рисунок 4.23 — Зависимость времени операторного слоя от числа объектов

Для 100 тыс., 1 млн, 2 млн и 5 млн объектов общее время составил 0,0137; 0,1362; 0,2730 и 0,7196 с, эмпирический показатель степени — 1,008558. Пропускная способность находится приблизительно в диапазоне 6,95–7,34 млн записей/с. Попытка 10 млн не выполнялась из-за зарегистрированного ограничителя памяти.

После получения локальных объяснений кэшированный операторный слой обработал до пяти миллионов записей с близкой к линейной зависимостью. Утверждение о полном сквозном конвейере на миллионах объектов не поддерживается: контрольные части модальных наборов содержат от 120 до 8 236 объектов, а стоимость исходного объяснителя исключена. Условия переноса результата заданы в разделе 4.15 и таблице А.12.

Масштабируемость характеризует техническую исполнимость, но практический вывод определяется тем, какие сведения получает пользователь, эксперт и аудитор.

ГЛАВА 4	Метод реализации системного оператора	FuzzyXAI
---------	--	----------

Доказательная основа раздела: E26–E28. Отдельно сохраняются измерения операторного слоя, граница сквозной проверки и контролируемое теневое воспроизведение.

4.23 Сквозные режимы применения и уровни объяснения

Публичный контракт различает четыре режима: принять (`accept`), краткая проверка (`short\_review`), полная проверка (`full\_review`) и блокировка (`block`). Ветвь определяется не одной шкалой уверенности, а типом ограничения. Низкая уверенность может привести к краткой проверке, нестабильность объяснения — к полной проверке, а формальное нарушение обязательного маршрута — к блокировке.

Режим	Основание	Результат и reason code
accept	Низкий predictive risk, evidence доступны, маршрут certified	Автоматическое применение; CERTIFIED_LOW_RISK
short_review	Умеренная неопределённость при корректном маршруте	Краткая проверка; PREDICTIVE_UNCERTAINTY
full_review	Explanation нестабильно или конфликтует	Проверка канонических свидетельств и альтернатив; EXPLANATION_INSTABILITY
block	Формальное нарушение обязательного маршрута	Запрет до исправления; код MISSING_MANDATORY_PROVENANCE

Таблица 4.36 — Семантика четырёх ветвей оценки действия (ActionAssessment)

Один канонический объект проецируется на три уровня адресата. Пользователь получает решение, несколько основных наблюдаемых причин, ограничения и действие. Эксперт дополнительно видит численные вклады, пороги, устойчивость и альтернативы. Аудитор получает полный граф происхождения, версии, контрольные суммы и коды оснований. Сокращение изменяет объём представления, но не создаёт независимое объяснение.

Элемент	Пользовательский уровень	Экспертный уровень	Аудиторский уровень
Результат модели	Класс/значение и краткая уверенность	Вероятность, margin, calibration	Версия модели, контрольная сумма, параметры запуска
Причины	До трёх предметных формулировок	Вклады, ранги, проценты, правила	Source payload, evidence ID, reference identity
Ограничения	Что мешает	Тип конфликта, stability,	Диагностические узлы и

ГЛАВА 4		Метод реализации системного оператора	FuzzyXAI
Элемент	Пользовательский уровень	Экспертный уровень	Аудиторский уровень
Действие	автоматическому применению	shift, missing channels	полный путь происхождение
	Принять, проверить или не применять	Стоимость, порог, альтернативный режим	Policy version, reason code, deterministic replay
Процесс обучения	Краткая фраза о выявленной	Траектория	Checkpoint IDs, timestamps, контрольные суммы; при
	нестабильности, если trace доступен	loss/confidence/margin и события забывания	отсутствии канала — D_incomplete

Таблица 4.37 — Проекция одного объяснительного объекта на уровни адресатов

История обучения является необязательным каналом свидетельств. Если сохранены контрольные состояния модели или траектории отдельных объектов, экспертное представление показывает изменения функции потерь, уверенности и отступа от границы решения, а также события забывания. Если история не сохранена, система не придумывает динамику и возвращает явное состояние неполноты. Тем самым процесс обучения отображается только при наличии измеренного журнала и не заменяется фиктивными числовыми значениями.

Пользовательский уровень

На контролируемом демонстрационном объекте № 85 система сформировала вывод: «Модель определила повышенный риск. Решение поддерживают высокая трещиноватость породы, водонасыщенность выше типичного уровня и небольшое расстояние до выработки. После 16-го этапа обучения модель вновь начала ошибаться на редких случаях этого типа, поэтому результат нельзя применять автоматически; его следует передать инженеру-геологу».

Связь с доказательным графом: пользовательская фраза является сокращённой проекцией утверждений C-005–C-016 и отображает только наблюдаемые причины, ограничение и действие.

Экспертный уровень

ГЛАВА 4	Метод реализации системного оператора	FuzzyXAI
---------	--	----------

На контролируемом демонстрационном объекте № 85 эксперт видит, что объект был впервые правильно распознан на 7-м этапе, событие забывания зафиксировано на 16-м этапе, полнота редкой подгруппы снизилась на 18 процентных пунктов, а правило R31 связывает высокую трещиноватость и малое расстояние с повышенным риском. Дополнительно показываются три похожих случая с мерами сходства 0,792; 0,627 и 0,216, а также проверочное изменение трещиноватости с 0,84 до 0,18, меняющее прогноз. Такое изменение является проверкой чувствительности модели, а не предметной рекомендацией.

Связь с доказательным графом: экспертная проекция раскрывает численные свидетельства, событие забывания, правило R31, подгруппу S4 и результаты проверок чувствительности, сохраняя связь с теми же утверждениями C-005–C-016.

Аудиторский уровень

На контролируемом демонстрационном объекте № 85 сохраняются идентификаторы утверждений C-005–C-016, ссылка на правило R31, событие забывания, сведения о подгруппе S4, версия модели, параметры объяснителя, контрольные суммы артефактов и полный путь от исходных свидетельств к действию `defer\_to\_human`. Пример подтверждает реализуемость многоуровневой проекции; понятность переработанной пользовательской формы дополнительно получила положительную качественную оценку участников, изучающих объяснимый искусственный интеллект.

Связь с доказательным графом: аудиторская проекция показывает полный путь происхождения утверждений C-005–C-016, версии

ГЛАВА 4	Метод реализации системного оператора	FuzzyXAI
---------	--	----------

компонентов, параметры объяснителя и контрольные суммы артефактов.

Реализованные пользовательская карточка и аудиторская панель, приведённые на рисунках 4.11 и 4.12, являются двумя проекциями одного маршрута. Их наличие подтверждает программную реализацию, а качественная оценка участниками поддерживает понятность переработанной пользовательской формы. Совпадение рекомендуемых действий с решениями специалистов и предметная безопасность в настоящей главе не оцениваются.

Уровни представления показывают, как один канонический объект используется разными адресатами. Далее все результаты сводятся по доказанным свойствам и ограничениям.

Доказательная основа раздела: E29 и артефакты Explanation Experience. Они фиксируют контракт практического контроллера и многоуровневые проекции одного канонического объекта.

4.24 Сводная оценка доказанных свойств и остаточных ограничений

Сводная оценка объединяет методологические риски, выполненные проверки и остаточные ограничения. Она позволяет отличить свойства, подтверждённые количественным экспериментом, от качественно оценённых характеристик представления и от свойств, для которых получен отрицательный результат.

Методологический риск	Выполненная проверка	Фактический результат	Статус
Смещение SHAP/LIME/Anchors/RuleFit	Три семейства сравнений	RuleFit перенесён в glass-box; Anchors оставлен локальным правилковым методом	Закрыто методологически
Нет GAM/EBM/FAST	GAM, EBM, RuleFit, sparse tree, rule list; FAST описан как отбор взаимодействий GA ² M	Измерены AUROC, Brier, сложность и время	Закрыто описательно
НЗ не даёт практического выигрыша	Независимые НЗ-P1-P4 и 14 базовых политик	P1 не превзошёл лучший базовый метод	Отрицательный результат подтверждён
Н5-P не предсказывает ошибку	Разделение Н5-S/Н5-P/Н5-A	Н5-A поддержана на controlled library; Н5-P	Закрыта граница функции

ГЛАВА 4	Метод реализации системного оператора	FuzzyXAI	
Методологический риск	Выполненная проверка	Фактический результат	Статус
Н6 противоречива	область обнаружимости Н6-А и сопоставимые контрольные правила Н6-В	остаётся отрицательной Н6-А поддержана ограниченно; Н6-В без inferential gate	Общий эффект не заявляется
Нет устойчивости правил vs SHAP/LIME	Явно разделены объекты устойчивости	Rule-set stability в замороженной доказательной базе отсутствует	Не закрыто численно; необоснованное утверждение запрещён
Автоматизированная проверка подменяет мнение людей	Автоматизированный этап дополнен качественной оценкой участниками, изучающими XAI	Основные замечания совпали; после исправлений объяснения признаны понятными	Закрыто качественно
Масштаб только 100 тыс.	Н9 до 5 млн объектов	Близко к линейному только операторный слой; исходный объяснитель исключён	Закрыто для операторного слоя
Нет анализа компонентной сетки	Н8 для четырёх модальностей	Действие устойчиво, состав первых причин чувствителен	Закрыто с ограничением
Нет полного объяснения для адресатов	Три проекции и канал training trace	Canopical evidence сохраняется; отсутствие trace маркируется	Закрыто на уровне контракта
Нет пользовательской оценки понятности	Проведена качественная оценка переработанных материалов	Участники, изучающие XAI, сочли объяснения понятными и приемлемыми	Закрыто качественно; без статистического утверждения

Таблица 4.38 — Методологические риски, выполненные проверки и остаточные границы

Гипотеза	Проверяемый результат	Область доказательства	Итог
H1	Сохранение локальной верности	6 000 пар	Подтверждена
H2	Локализация отсутствующих каналов	Контролируемые удаления	Подтверждена
H3	Преимущество политики применения	5 независимых наборов	Не подтверждена
H4	Снижение сложности представления	504 260 объектов	Подтверждена
H5-S	Обнаружение структурных разрывов	Контролируемые нарушения	Подтверждена
H5-P	Предсказание ошибки модели	Подтверждающий контур	Не подтверждена
H5-A	Структурная сертификация	40 шаблонов и 14 композиций	Подтверждена в ограниченной области
H6-general	Общий эффект исключения правила	Реальные наборы	Не подтверждена
H6-A	Обнаружимость внедрённых правил	Заранее заданная синтетическая область	Подтверждена в ограниченной области
H6-B	Эффект реальных правил	2 табличных набора	Статистически не подтверждена
H7-A	Сохранение канонических артефактов	17 404 артефакта	Подтверждена
H7-B	Улучшение сокращённой проекции	Описательный анализ	Не подтверждена

ГЛАВА 4	Метод реализации системного оператора	FuzzyXAI	
Гипотеза	Проверяемый результат	Область доказательства	Итог
H8	Устойчивость к компонентной сетке	Анализ без целевых меток	Ограниченное измерение
H9	Масштабируемость	Кэшированный операторный слой	Ограниченное измерение

Таблица 4.39 — Итоговый статус исходных и новых экспериментальных гипотез

Наиболее сильные положительные результаты относятся к H1, H2, H4, H5-S, H5-A, H6-A и H7-A, однако три последних имеют явно ограниченную область. H3, H5-P, H6-general, H6-B и H7-B не подтверждены. H8 и H9 являются ограниченными техническими измерениями. Качественная пользовательская оценка переработанных объяснений проведена и поддерживает их понятность; предметная безопасность и эффективность действий не входят в подтверждённые результаты.

Доказательная основа раздела: E17. Итоговый реестр утверждений запрещает положительную формулировку для свойства, не достигшего заранее заданного критерия.

4.25 Доказательная трассировка и воспроизводимость результатов

Доказательная трассировка встроена в логику экспериментальных разделов, а не вынесена в отдельный перечень, оторванный от интерпретации. После каждого ключевого эксперимента указаны группы источников E01–E29, на которых основаны числа, статистические выводы и ограничения. Такой способ сохраняет проверяемость и одновременно не превращает основной текст в распечатку файловой структуры архива.

Источники E01 и E03–E10 описывают линию выпуска, данные, разбиения, аудит утечек, протокол и заявленное восстановление этапа расчёта метрик. E11–E17 относятся к H3, таксономии сравнений и итоговому реестру утверждений. E18–E24 фиксируют H5, H6 и H7. E25–E29 содержат

ГЛАВА 4	Метод реализации системного оператора	FuzzyXAI
---------	--	----------

анализ компонентной сетки, масштабирование, теневое воспроизведение и контракт практического контроллера.

Первоначальный этап расчёта итоговых метрик был признан недействительным из-за ошибки разбора внешнего контейнера меток. До возникновения ошибки прогнозы, объяснения, признаки P0/P1 и действия политик уже были сформированы и хэшированы без использования контрольных меток. После отдельной фиксации отклонения повторно вычислялись только метрики по неизменяемым артефактам; обучение, настройка и выбор политик не повторялись. Поэтому результат рассматривается как подтверждающий запуск с зарегистрированным протокольным отклонением, а не как идеальный однократный запуск.

Карта 38 существенных числовых значений связывает каждое число с файлом, локатором и контрольной суммой в едином выпуске `fuzzyxai-final-practical-closure-1a71bae98f15.zip`. Основной код соответствует версии v1.3.0 и коммиту 1a71bae98f1554430d537670018dce7dc889e25f. В документальной редакции модели и экспериментальные результаты не пересчитывались.

Каждый результат интерпретируется только в пределах соответствующего эксперимента. Подтверждённое свойство относится к указанной области данных и протокола; отрицательный результат не заменяется более узким положительным утверждением; ограниченное измерение не переносится на полный сквозной процесс. Качественная оценка понятности рассматривается отдельно от статистических гипотез и не используется для вывода о предметной безопасности.

Тем самым доказательная трассировка не добавляет новых результатов, а устанавливает границы допустимого текста. Итоговые выводы формулируются только в пределах таблицы 4.35 и доказательных источников, указанных непосредственно в соответствующих разделах.

ГЛАВА 4	Метод реализации системного оператора	FuzzyXAI
---------	--	----------

4.26 Современный прикладной контур и полная вычислительная стоимость

Для проверки переносимости на современную предварительно обученную модель дополнительно выполнен зафиксированный до расчёта результатов текстовый контур AG News с DistilBERT. Модель и ревизии источников не переобучались и не заменялись после просмотра результатов. Предсказания получены для 127 439 допущенных объектов, а два локальных объяснения построены для 2 000 стратифицированно выбранных объектов из изолированной выборки. Числа этого раздела связаны с 386 числовыми записями карты доказательств.

4.26.1 Данные, модель и контроль утечек

До запуска модели аудит обнаружил повторы в закреплённой ревизии исходного набора. Официальная test-часть была сохранена, а 161 повторяющихся или совпадающих с test обучающих строк исключены до модельных вычислений. После исключения размеры частей составили 99 839, 20 000 и 7 600 объектов. Пересечения идентификаторов и нормализованных текстов между частями равны нулю. Это зарегистрированное отклонение не изменило модель, политики, показатели или критерии успеха.

Набор	Всего объектов	Обучение	Настройка	Изолирован ная выборка	Точность модели	Объяснения	Сохранение хэша
AG News	127 439	99 839	20 000	7 600	0,9479	2 000	1

Таблица 4.40 — Современный прикладной контур AG News

4.26.2 Локальные объяснения и каноническое сохранение

Для каждого выбранного объекта рассчитаны Integrated Gradients и маскирование токенов. Сохраняемый канонический объект включает идентичность токена, знак, величину, ранг, параметры объяснителя, ревизию модели и контрольную сумму. Доля точного сохранения канонического хэша составила 1. Значения верности удаления, устойчивости к малым

ГЛАВА 4	Метод реализации системного оператора	FuzzyXAI
---------	--	----------

возмущениям и согласия двух методов приведены как измерения данного контура, а не как доказательство универсального превосходства.




Рисунок 4.24 — Распределение показателей локального объяснения в современном текстовом контуре

4.26.3 Политики при сопоставимом покрытии

Все политики направляют на проверку одинаковую долю объектов для каждого бюджета. Основной бюджет равен 20 %, а лучшая простая политика выбрана только на validation-части. Контрольные метки изолированной части открывались исключительно после записи и хэширования оценок риска и действий политик. В заранее зафиксированном первичном сравнении полный контроллер не показал статистически подтверждённого преимущества над простой политикой, выбранной только на validation-части. Этот результат сохранён без подбора порога после открытия меток и согласуется с отрицательным статусом H3-original.

ГЛАВА 4	Метод реализации системного оператора	FuzzyXAI
---------	--	----------

Первичный scoring-пакет был признан недействительным при послерезультатном техническом аудите: контрольная политика безусловного принятия ошибочно получила общий бюджет проверки, а конечная bootstrap-оценка могла быть записана как $p = 0$. Исходный пакет сохранён с invalid marker. Затем выполнено только повторное вычисление метрик по неизменённым прогнозам, score rows, порогам и выбранной baseline-политике; модели и действия остальных политик не менялись. Поэтому итог трактуется как scoring-only recovery с зарегистрированным протокольным отклонением.

Политика	Покрытие	Ошибочные действия	Риск	На проверке	Ложные блокировки	Стоимость
Калибр. уверенность	0,8000	72	0,0118	1 520	0	2 240
Предиктивный риск P0	0,8000	72	0,0118	1 520	0	2 240
Риск P1	0,8000	72	0,0118	1 520	0	2 240
Энтропия	0,8000	73	0,0120	1 520	0	2 250
Взвешенная	0,8000	73	0,0120	1 520	0	2 250
Порог уверенности	0,8000	74	0,0122	1 520	0	2 260
OR	0,8000	101	0,0166	1 520	0	2 530
Расхождение	0,8000	308	0,0507	1 520	0	4 600
Полный FuzzyXAI	0,8000	308	0,0507	1 520	0	4 600
Происхождение	0,8000	312	0,0513	1 520	0	4 640
Случайная	0,8000	314	0,0516	1 520	0	4 660
Безусловное принятие	1	396	0,0521	0	0	3 960

Таблица 4.41 — Сопоставление политик при бюджете проверки 20 %

Первичная абсолютная разность долей ошибочных автоматических действий составляет -0,031053, 95%-й доверительный интервал [-0,035263; -0,026974], скорректированное значение $p = 0,017996$. Знак эффекта трактуется относительно простой политики, заранее выбранной на validation-части.

ГЛАВА 4	Метод реализации системного оператора	FuzzyXAI
---------	--	----------




Рисунок 4.25 — Риск и автоматическое покрытие политик при одинаковых бюджетах проверки

4.26.4 Типизированная проверка маршрута

Независимое сравнение охватывает корректные маршруты, одиночные нарушения, их композиции и типы, не участвовавшие в настройке простых базовых схем. Типизированный валидатор возвращает не только общий запрет, но также тип и компонент нарушения. Результат относится к зарегистрированной библиотеке и не доказывает обнаружение произвольного неизвестного сбоя.

Группа	Метод	N	Точность	Полнота	F1	Ложная сертификация	Локализация
Корректный	if-else	1 000	0	0	0	0	1
Отложенные	if-else	1 000	0	0	0	1	0
Композиции	if-else	4 000	1	1	1	0	0
Одиночные	if-else	1 000	1	1	1	0	1
Корректный	OR	1 000	0	0	0	0	1
Отложенные	OR	1 000	0	0	0	1	0
Композиции	OR	4 000	1	0,8000	0,8889	0,2000	0,0500

ГЛАВА 4		Метод реализации системного оператора			FuzzyXAI		
Группа	Метод	N	Точность	Полнота	F1	Ложная сертификация	Локализация
и							
Одиночные	OR	1 000	1	0,4000	0,5714	0,6000	0,4000
Корректный	Типизированный	1 000	0	0	0	0	1
Отложенные	Типизированный	1 000	1	1	1	0	1
Композиции	Типизированный	4 000	1	1	1	0	1
Одиночные	Типизированный	1 000	1	1	1	0	1
Корректный	Взвешенная	1 000	0	0	0	0	1
Отложенные	Взвешенная	1 000	0	0	0	1	0
Композиции	Взвешенная	4 000	1	1	1	0	0
и							
Одиночные	Взвешенная	1 000	1	1	1	0	0

Таблица 4.42 — Диагностика одиночных, композиционных и отложенных нарушений




Рисунок 4.26 — Качество обнаружения нарушений для четырёх проверяющих схем

ГЛАВА 4	Метод реализации системного оператора	FuzzyXAI
---------	--	----------

4.26.5 Полная стоимость конвейера

Время разложено на модель, внешний объяснитель, собственный слой FuzzyXAI и сериализацию. Выполнено по 5 измерений после прогрева. Окружение: AMD Ryzen 7 7840HS w/ Radeon 780M Graphics; RAM 15 895 953 408 байт; NVIDIA GeForce RTX 4060 Laptop GPU; Python 3.12.12; PyTorch 2.7.1; доступно 16 вычислительных потоков. GPU не была изолирована: параллельно выполнялся независимый пользовательский процесс, зафиксированный в environment snapshot. Поэтому абсолютные времена являются описательными для данного разделяемого окружения. Показатели прежнего опыта на 5 млн записей по-прежнему относятся только к кэшированному операторному слою и не используются как характеристика полного конвейера.

Объяснитель	N	Повторы	Модель, с	Объяснитель, с	FuzzyXAI, с	Сериализация, с	Полное время, с
IG	1	5	0,0089	0,0525	0,0004	0,0000	0,0623
IG	10	5	0,0496	0,9369	0,0019	0,0000	0,9885
IG	100	5	0,3885	7,3378	0,0147	0,0004	7,7779
IG	1 000	5	4,0598	65,2550	0,1389	0,0041	68,4645
Маскированное	1	5	0,0065	0,0232	0,0004	0,0000	0,0290
Маскированное	10	5	0,0288	0,6706	0,0017	0,0000	0,7061
Маскированное	100	5	0,4026	9,8981	0,0138	0,0004	10,3347
Маскированное	1 000	5	3,2384	63,2649	0,1309	0,0039	67,5205
Маскированное	10 000	5	38,1035	689,3697	1,3164	0,0436	728,9557

Таблица 4.43 — Время этапов современного текстового контура

Объяснитель	N	Объектов/с	Пиковая RAM, байт	Пиковая VRAM, байт	Доля FuzzyXAI	Доля объяснителя
IG	1	16,0425	1 662 472 192	500 442 112	0,0060	0,8424
IG	10	10,1167	1 663 459 328	1 053 560 320	0,0020	0,9479
IG	100	12,8570	1 666 306 048	1 053 560 320	0,0019	0,9434
IG	1 000	14,6061	1 680 588 800	1 053 560 320	0,0020	0,9531
Маскированное	1	34,4791	1 675 153 408	356 588 032	0,0127	0,7999
Маскированное	10	14,1621	1 675 964 416	474 695 168	0,0025	0,9498
Маскированное	100	9,6762	1 678 348 288	612 951 552	0,0013	0,9578
Маскированное	1 000	14,8103	1 690 812 416	612 952 576	0,0019	0,9370

ГЛАВА 4		Метод реализации системного оператора		FuzzyXAI		
Объяснитель	N	Объектов/с	Пиковая RAM, байт	Пиковая VRAM, байт	Доля FuzzyXAI	Доля объяснителя
е						
Маскировани	10 000	13,7183	1 801 818 112	612 952 576	0,0018	0,9457
е						

Таблица 4.44 — Производительность, память и доли времени




Рисунок 4.27 — Декомпозиция полного времени по этапам конвейера

4.26.6 Воспроизводимый сквозной объект

Отдельный объект выбран детерминированным правилом до просмотра его метки. Для него сохранены ссылка на вход, прогноз, локальные вклады, канонический артефакт, граф происхождения, диагностическое состояние, действие, пользовательская карточка, аудиторский вывод и время каждого этапа. Контроллер выбрал действие «short review», структурный статус «certified»; полное измеренное время воспроизведения составило 0,371056 с. Текст исходного объекта не включён в выпуск из-за неопределённого статуса лицензии upstream-карточки AG News.

Артефакт	Проверяемое содержание
Ссылка на вход	Идентификатор, исходный split, индекс и SHA256 нормализованного текста
Локальное объяснение	Токены и значения Integrated Gradients и маскирования
Канонический объект	Неизменяемая полезная нагрузка и контрольная сумма
Граф происхождения	Переход от объекта и модели к объяснению и действию
Диагностика	Структурный статус, коды причин и отсутствующие свидетельства

ГЛАВА 4	Метод реализации системного оператора	FuzzyXAI
Артефакт	Проверяемое содержание	
Аудит	Trace ID, версии и контрольная сумма детерминированного повтора	

Таблица 4.45 — Состав воспроизводимого сквозного примера

4.26.7 Статус новых проверок

Проверка	Результат	Область
H3-original	не подтверждена	зафиксированный выпуск v1.3.0
H5-P-original	не подтверждена	зафиксированный выпуск v1.3.0
H6-general	не подтверждена	зафиксированный выпуск v1.3.0
V13-H1	подтверждена в указанной области	2000 AG News explanations
V13-H2	подтверждающее преимущество не установлено	сопоставимое покрытие, изолированная выборка
V13-H3	подтверждена для зарегистрированной библиотеки	зарегистрированные одиночные и композиционные нарушения
V13-H4	описательное измерение	полный конвейер, N=1...10 000
V13-H5	разведочный результат	отложенные типы нарушений

Таблица 4.46 — Статус проверок дополнительного контура v13

Новый контур расширяет эмпирическую базу современной моделью, крупным набором, сопоставимыми бюджетами и полным измерением времени. Он не меняет зафиксированные отрицательные результаты H3-original, H5-P-original и H6-general и не создаёт утверждений о пользовательской понятности или предметной безопасности.

4.27 Обсуждение результатов и выводы по главе

Расширенная экспериментальная программа подтверждает вычислительную состоятельность FuzzyXAI как системного объяснительно-аудиторского слоя. Метод принимает разнородные локальные объяснения, сохраняет их в канонической форме, связывает утверждения с происхождением, локализует предусмотренные нарушения, выбирает минимально достаточное представление и формирует воспроизводимый след действия.

Положительные результаты не следует интерпретировать как универсальное улучшение точности прогнозирования. H1 показывает отсутствие искажения исходного объяснения; H2 и H5-S/H5-A — корректность зарегистрированных структурных контрактов; H4 — снижение

ГЛАВА 4	Метод реализации системного оператора	FuzzyXAI
---------	--	----------

сложности представления без ухудшения зафиксированного риска; H7-A — точное сохранение 17 404 канонических артефактов. H6-A характеризует область обнаружимости внедрённых правил, но не общий эффект реальной абляции.

Отрицательные результаты H3, H5-P и H6-general имеют самостоятельную научную ценность. Они показывают, что структурная корректность маршрута, происхождение и конфликт не являются универсальными предикторами ошибки или безопасности. Тем самым разграничиваются аудит объяснительного маршрута и оценка истинности прогноза — два ортогональных свойства, которые нельзя подменять друг другом. FuzzyXAI предоставляет воспроизводимый диагностический слой, но не заменяет предметную проверку, не гарантирует повышение точности и не обосновывает автоматическое применение решения без отдельной калибровки.

Сопоставление с современными аналогами выполнено по трём корректно разделённым уровням. SHAP, LIME и Anchors оцениваются как постмодельные объяснения одной модели; GAM, EBM, RuleFit и другие внутренне интерпретируемые подходы — как самостоятельные предикторы; пороговые, конформные и риск-ориентированные схемы P0/P1 — как политики применения. FuzzyXAI не объявляется победителем общей таблицы, поскольку выполняет системную функцию над объяснительным маршрутом.

Масштабируемость кэшированного операторного слоя проверена отдельно до пяти миллионов записей. Дополнительный контур v13 измеряет полное время модели, объяснителя, FuzzyXAI и сериализации на доступных размерах; эти два результата не смешиваются. Анализ компонентной сетки показал высокую устойчивость действия в рекомендованном диапазоне и одновременно нулевое совпадение первых компонентов вне базовой

ГЛАВА 4	Метод реализации системного оператора	FuzzyXAI
---------	--	----------

конфигурации. Поэтому гранулярность должна фиксироваться как часть происхождения объяснения, а результаты Н8 и Н9 нельзя переносить на полный сквозной конвейер без отдельного измерения.

Практическая значимость установлена для инженерии проверяемых объяснений, воспроизводимого аудита, контроля происхождения и ограничения действия при формальном нарушении маршрута. Редакционная апробация не используется как доказательство понятности, предметной безопасности или правильности рекомендуемого действия.

Практическая реализация представлена публичным API, адаптерами четырёх модальностей, типизированным маршрутом, проверяемым доказательным следом и экспортом доказательного пакета. Дополнительный контур с DistilBERT и AG News подтверждает техническую переносимость на современную предварительно обученную модель и раскрывает полную вычислительную стоимость. Сквозной пример подтверждает, что диагностика и действие вычисляются из входных значений, формул согласования, редукции и риска, а затем независимо проверяются модулем verifier. Этот результат относится к работоспособности программного контура и не изменяет отрицательные статусы Н3, Н5-Р, Н6-general, Н6-В и Н7-В.

Итоговый научный вывод: FuzzyXAI реализует воспроизводимый системный объяснительно-аудиторский слой, который сохраняет исходные свидетельства, обеспечивает трассируемость, поддерживает минимально достаточные представления и локализует зарегистрированные структурные нарушения. Метод не подтверждён как универсально лучшая политика действия, предиктор ошибки модели или средство общего улучшения правилowej системы. Эти отрицательные результаты не скрываются, а определяют научно обоснованную область применения.

ГЛАВА 4	Метод реализации системного оператора	FuzzyXAI
Научный результат		Содержание и область доказательства
Вычислительная форма		Маршрут $(M, x, \Pi, \Omega) \rightarrow (E, D, \chi, \tau)$ с явной неполнотой и доказательным графом
Межмодальная переносимость		Таблицы, изображения, текст и временные ряды; разные семейства моделей и объяснителей
Сохранение локального сигнала		6 000 парных сравнений без изменения измеренной локальной верности
Локализация неполноты		2 000 контролируемых удалений без ложной сертификации
Минимально достаточное представление		504 260 объектов; сложность снижена с 8 до 3,137 при сохранении риска
Структурная валидность		4 000 разрывов и отдельная библиотека 40 шаблонов нарушений и 14 композиций
Канонические свидетельства		17 404 артефакта с точным совпадением контрольных сумм
Чувствительность гранулярности		Действие устойчивее состава первых причин; гранулярность включается в происхождение
Масштабируемость		До 5 млн записей для кэшированного операторного слоя; сквозное утверждение запрещено
Границы метода		H3, H5-P и H6-general не подтверждены; количественная пользовательская и предметная проверка не проводилась

Таблица 4.47 — Итоговый научный вклад и экспериментальные границы главы

Список литературы к главе 4

[1] Ribeiro M. T., Singh S., Guestrin C. “Why Should I Trust You?” Explaining the Predictions of Any Classifier // Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining. 2016. P. 1135–1144. DOI: 10.1145/2939672.2939778.

[2] Lundberg S. M., Lee S.-I. A Unified Approach to Interpreting Model Predictions // Advances in Neural Information Processing Systems. 2017. Vol. 30.

[3] Ribeiro M. T., Singh S., Guestrin C. Anchors: High-Precision Model-Agnostic Explanations // Proceedings of the AAAI Conference on Artificial Intelligence. 2018. Vol. 32. No. 1. P. 1527–1535. DOI: 10.1609/aaai.v32i1.11491.

[4] Friedman J. H., Popescu B. E. Predictive Learning via Rule Ensembles // The Annals of Applied Statistics. 2008. Vol. 2. No. 3. P. 916–954. DOI: 10.1214/07-AOAS148.

ГЛАВА 4	Метод реализации системного оператора	FuzzyXAI
---------	--	----------

[5] Selvaraju R. R. et al. Grad-CAM: Visual Explanations from Deep Networks via Gradient-Based Localization // Proceedings of ICCV. 2017. P. 618–626.

[6] Sundararajan M., Taly A., Yan Q. Axiomatic Attribution for Deep Networks // Proceedings of ICML. 2017. Vol. 70. P. 3319–3328. arXiv:1703.01365.

[7] Doshi-Velez F., Kim B. Towards a Rigorous Science of Interpretable Machine Learning. arXiv:1702.08608. 2017.

[8] Miller T. Explanation in Artificial Intelligence: Insights from the Social Sciences // Artificial Intelligence. 2019. Vol. 267. P. 1–38. DOI: 10.1016/j.artint.2018.07.007.

[9] Rudin C. Stop Explaining Black Box Machine Learning Models for High Stakes Decisions and Use Interpretable Models Instead // Nature Machine Intelligence. 2019. Vol. 1. P. 206–215. DOI: 10.1038/s42256-019-0048-x.

[10] Barredo Arrieta A. et al. Explainable Artificial Intelligence: Concepts, Taxonomies, Opportunities and Challenges toward Responsible AI // Information Fusion. 2020. Vol. 58. P. 82–115. DOI: 10.1016/j.inffus.2019.12.012.

[11] Murdoch W. J. et al. Definitions, Methods, and Applications in Interpretable Machine Learning // Proceedings of the National Academy of Sciences. 2019. Vol. 116. No. 44. P. 22071–22080. DOI: 10.1073/pnas.1900654116.

[12] Holm S. A Simple Sequentially Rejective Multiple Test Procedure // Scandinavian Journal of Statistics. 1979. Vol. 6. No. 2. P. 65–70.

[13] Wilcoxon F. Individual Comparisons by Ranking Methods // Biometrics Bulletin. 1945. Vol. 1. No. 6. P. 80–83.

[14] Efron B., Tibshirani R. J. An Introduction to the Bootstrap. New York: Chapman & Hall, 1993.

ГЛАВА 4	Метод реализации системного оператора	FuzzyXAI
---------	--	----------

[15] Blackard J. A., Dean D. J. Comparative Accuracies of Artificial Neural Networks and Discriminant Analysis in Predicting Forest Cover Types from Cartographic Variables // Computers and Electronics in Agriculture. 1999. Vol. 24. No. 3. P. 131–151. DOI: 10.1016/S0168-1699(99)00046-0.

[16] Xiao H., Rasul K., Vollgraf R. Fashion-MNIST: a Novel Image Dataset for Benchmarking Machine Learning Algorithms. arXiv:1708.07747. 2017.

[17] Lang K. NewsWeeder: Learning to Filter Netnews // Proceedings of the 12th International Conference on Machine Learning. 1995. P. 331–339.

[18] Bagnall A. et al. The Great Time Series Classification Bake Off: a Review and Experimental Evaluation of Recent Algorithmic Advances // Data Mining and Knowledge Discovery. 2017. Vol. 31. P. 606–660. DOI: 10.1007/s10618-016-0483-9.

[19] Pedregosa F. et al. Scikit-learn: Machine Learning in Python // Journal of Machine Learning Research. 2011. Vol. 12. P. 2825–2830.

[20] Paszke A. et al. PyTorch: An Imperative Style, High-Performance Deep Learning Library // Advances in Neural Information Processing Systems. 2019. Vol. 32.

[21] Hastie T. J., Tibshirani R. J. Generalized Additive Models. London: Chapman & Hall, 1990. 352 p.

[22] Lou Y., Caruana R., Gehrke J., Hooker G. Accurate Intelligible Models with Pairwise Interactions // Proceedings of the 19th ACM SIGKDD International Conference on Knowledge Discovery and Data Mining. 2013. P. 623–631. DOI: 10.1145/2487575.2487579.

[23] Nori H., Jenkins S., Koch P., Caruana R. InterpretML: A Unified Framework for Machine Learning Interpretability. arXiv:1909.09223. 2019.

[24] Moro S., Cortez P., Rita P. A Data-Driven Approach to Predict the Success of Bank Telemarketing // Decision Support Systems. 2014. Vol. 62. P. 22–31. DOI: 10.1016/j.dss.2014.03.001.

ГЛАВА 4	Метод реализации системного оператора	FuzzyXAI
---------	--	----------

[25] Yeh I.-C., Lien C.-H. The Comparisons of Data Mining Techniques for the Predictive Accuracy of Probability of Default of Credit Card Clients // Expert Systems with Applications. 2009. Vol. 36. No. 2. P. 2473–2480. DOI: 10.1016/j.eswa.2007.12.020.

[26] Shoulder Implant X-Ray Manufacturer Classification [Dataset]. UCI Machine Learning Repository. 2020. DOI: 10.24432/C5F893.

[27] Almeida T. A., Hidalgo J. M. G., Yamakami A. Contributions to the Study of SMS Spam Filtering: New Collection and Results // Proceedings of the ACM Symposium on Document Engineering. 2011. P. 259–262. DOI: 10.1145/2034691.2034742.

[28] Anguita D., Ghio A., Oneto L., Parra X., Reyes-Ortiz J. L. A Public Domain Dataset for Human Activity Recognition Using Smartphones // Proceedings of ESANN. 2013. P. 437–442.

Приложение А. Детализированные экспериментальные и технические таблицы

В приложение перенесены полные замороженные строки, технические параметры и факторные сетки, которые необходимы для воспроизводимости, но перегружают основной научный текст. Перенос не изменяет ни одного числового результата или статуса гипотезы.

Объектов	Полное время, с	Накладные расходы, с	Пиковая память, МБ
1 000	0,0098	0,0085	0,65
5 000	0,0453	0,0421	3,19
10 000	0,0925	0,0855	6,38
50 000	0,4727	0,4209	31,86
100 000	0,8656	0,8080	63,71

Таблица А.1 — Ранний эталонный контур масштабирования

Объектов	Узлов	Рёбер	Сериализация, байт
1 000	5 000	4 000	46 178
5 000	25 000	20 000	237 888
10 000	50 000	40 000	480 379
50 000	250 000	200 000	2 436 956
100 000	500 000	400 000	4 785 544

Таблица А.2 — Размер доказательного графа и сериализации

ГЛАВА 4			Метод реализации системного оператора		FuzzyXAI	
Метод	N	Верн.	Уст.	Полн.	Элем.	Время
SHAP	100	0,277	0,998	0,920	5,00	0,821
LIME	100	0,273	0,998	0,770	5,00	0,750
Anch.	100	0,960	—	0,960	2,17	13,713
RuleFit	2000	0,749	—	0,749	29,00	5,561
S+L	100	0,275	0,998	0,845	5,00	1,572
FX+S	100	0,277	0,998	0,920	5,00	0,821
FX full	100	0,275	0,998	0,845	5,00	1,572

Таблица А.3 — Полное сравнение объяснителей на раннем контролируемом контуре

Таблица А.4 — Полное сравнение ранних политик применения

Схема

Авт. покр.

Ошиб. принято

Ручная проверка

Блок

Ложн. блок

Средн. стоимость

P1: порог уверенности

0,7405

245

519

0

0

0,8792

P2: порог + SHAP

0,4045

146

1191

0

0

1,1852

ГЛАВА 4	Метод реализации системного оператора	FuzzyXAI
---------	--	----------

P3: согласие SHAP/LIME

0,1775

69

1645

0

0

1,3718

P4: устойчивость + разрыв

0,4920

185

996

20

18

1,1395

P5: P4 + история

0,4920

185

996

20

18

1,1395

P6: все на проверку

0,0000

0

2000

0

0

1,5000

ГЛАВА 4	Метод реализации системного оператора	FuzzyXAI
---------	--	----------

P7: все принять

1,0000

467

0

0

0

0,9340

Метрика	Средняя разность	95%-й ДИ	p Холма	Интерпр.
Точность	-0,000120	[-0,000500; 0,000320]	0,946174	Общий эффект отсутствует
Полнота	-0,001381	[-0,001854; -0,000947]	0,000111	Статистически различимо, практически мало
F1	-0,000403	[-0,000771; 0,000017]	0,042346	Малый пограничный эффект
Полнота редкой группы	0,000000	[0,000000; 0,000000]	1,000	Эффект отсутствует
F1 редкой группы	0,000000	[0,000000; 0,000000]	1,000	Эффект отсутствует

Таблица А.5 — Повторная десятикратная проверка удаления правила

Объект проверки	Возмущение или повтор	Метрика	Значение	Граница интерпретации
SHAP	Повторный запуск объяснителя	Устойчивость локального объяснения	0,9977	Контролируемый табличный контур
LIME	Повторный запуск объяснителя	Устойчивость локального объяснения	0,9977	Контролируемый табличный контур
SHAP + LIME	Повторный запуск совмещённого контура	Устойчивость локального объяснения	0,9977	Не является причинной валидностью
Прогноз модели	Шум признаков	Доля изменившихся прогнозов	0,0180	Интенсивность фиксирована протоколом
Прогноз модели	Пропуски и медианное заполнение	Доля изменившихся прогнозов	0,0275	Проверяется прогноз, не набор причин
Прогноз модели	Сдвиг распределения	Доля изменившихся прогнозов	0,0850	Максимальный измеренный эффект
Прогноз модели	Смена фоновой выборки	Доля изменившихся прогнозов	0,0055	Относится к выбранному reference set
Топ-3 причин	Гауссов шум $\sigma = 0,05$ и $0,20$	Jaccard	Не измерено	Новый эксперимент; численное значение не подставляется

Таблица А.6 — Полная детализация робастности прогноза и объяснения

ГЛАВА 4	Метод реализации системного оператора	FuzzyXAI
Элемент	Зафиксированное значение	
Основной evidence commit	e34e52fb8ae62ee1be043d6d5b26a0c9214a0572	
Основная ветка	feat/q1-final-closure	
AI-review pipeline commit	1f5fd774afadde5fe03aed07eaf44f3f54967736	
Профиль	full_q1_final	
Python	3.11.15	
Платформа	Linux-6.17.0-1020-azure-x86_64-with-glibc2.39	
Число потоков	1	
Dockerfile	Dockerfile.q1-final	
Команда	docker run --rm fuzzyxai-q1-final make reproduce-q1-final	
Публичный CI	29740096302	
Статус Docker	PASS	
SHA256 formative AI-review ZIP	c13e614a34c524ec1009d17856b1f79ea83df8302c3dcba2e4869c3966557414	
SHA256 aggregate JSONL	08d9a197ac955ab22c741711efde02a83c59b92cb9efff2114f52423a6f29c3d	
Stable release	технический выпуск v1.3.0; стабильность относится к коду и артефактам, а не к предметной безопасности	

Таблица A.7 — Параметры воспроизводимого запуска

Критерий	Средняя оценка 0–4
Фактическая согласованность	4,000
Прослеживаемость	4,000
Честность представления неопределённости	1,768
Качество предлагаемого действия	3,346
Понятность	2,761
Полнота ограничений	2,336
Контроль чрезмерного доверия	3,186
Корректность причинных формулировок	4,000
Соответствие аудитории	3,000
Общая пригодность	3,147

Таблица A.8 — Полные оценки формирующего AI-рецензирования

Этап	Идентификатор	Назначение	Научная граница
Многомодальное Q1-замораживание	e34e52fb8ae6	H1–H6, статистика, воспроизводимость	H3, H5-P и H6-general отрицательны
Формирующий AI-аудит	1f5fd774afad	240 случаев, 720 слепых вариантов	Предварительный этап дополнен качественной пользовательской оценкой; статистические гипотезы не изменяются
Технический stable release	v1.3.0 / 1a71bae98f15	Код, контракты, единый архив и проверки	Stable относится к техническому выпуску
Документационная фиксация	1e894a689de1	Глава и карта evidence	Не изменяет замороженной доказательной базе

Таблица A.9 — Доказательная линия последовательных выпусков

Проверка	Сравнение или компонент	Изменение	Интервал / p	Вывод
Основная	P1 против взвешенной политики	–3,894 %	[–0,027123; 0,019860], p=0,999999	Преимущество отсутствует
Дополнительная	P1 против P0	+0,387 %	[–0,021214;	Добавочная польза

ГЛАВА 4	Метод реализации системного оператора	FuzzyXAI
----------------	--	-----------------

Проверка	Сравнение или компонент	Изменение	Интервал / p	Вывод
			0,015218], p=0,616690	не показана
Исключение	Расхождение объяснителей	+7 действий	—	Малое изменение
Исключение	Расхождение моделей	+4 действия	—	Малое изменение
Исключение	Полнота происхождения	–1 действие	—	Устойчивого эффекта нет
Исключение	Потеря редукции	–3 действия	—	Устойчивого эффекта нет
Исключение	Класс представления	–12 действий	—	Устойчивого эффекта нет
Исключение	Нарушение маршрута	0 действий	—	В контрольной выборке слой не активирован
Исключение	Сдвиг распределения	–2 действия	—	Устойчивого эффекта нет
Исключение	Устойчивость объяснения	+22 действия	—	Требует отдельной проверки

Таблица А.10 — Полная таблица P0/P1 и исключения компонентов

Показатель Н6-А	Значение	Метод оценки	Ограничение
Число конфигураций в области	243	Факторная сетка	Строки имеют общие параметры
Доля обнаружения	1,0000	Точечная оценка	Только заданная область
Интервал в пакете v1.3.0	[1,0000; 1,0000]	2 000 выборок percentile bootstrap	Вырожден при 243 единицах
Точный биномиальный интервал	[0,984934; 1,0000]	Клоппер—Пирсон, 95 %	Анализ чувствительности; предполагает независимость строк
Доля ложных обнаружений	0,006316	Зафиксированный расчёт	Синтетический контур
Правильность знака	1,0000	Зафиксированный расчёт	Синтетический контур

Таблица А.11 — Факторная сетка области обнаружимости Н6-А

Условие измерения	Зафиксированное значение	Ограничение воспроизводимости
Режим	Потоковый, кэшированный операторный слой	Не полный конвейер
Размер пакета	10 000 объектов	Зафиксирован в коде и результатах
Вход одного объекта	12 чисел float32, 48 байт без накладных расходов	Полный размер объекта не измерен
Повторы	Один запуск на размер и один повтор для 100 тыс.	Межзапусковый разброс не оценён
p50/p95/p99	Квантили задержки отдельных пакетов	Не интервалы по независимым запускам
Процессор	Не зарегистрирован в артефакте Н9	Нельзя восстанавливать по текущей машине
Оперативная память	Не зарегистрирована	Peak RSS относится ко всему процессу
Операционная система	Отдельный снимок Linux не связан однозначно с Н9	В основном выводе не используется
Число потоков	Не зарегистрировано для Н9	Влияние внутренних потоков NumPy не оценено

ГЛАВА 4	Метод реализации системного оператора	FuzzyXAI
----------------	--	-----------------

Таблица А.12 — Полные условия измерения масштабируемости Н9